

大涨240%，Doc-Researcher确立多模态文档深度研究新范式


PaperAgent 2025年11月3日 17:18 湖北

大家好，我是PaperAgent，不是Agent！

当大模型遇上“看不懂”的文档

在ChatGPT引领的AI革命中，大语言模型（LLM）展现了惊人的推理能力。然而，当面对专业领域的复杂文档时，它们却常常“束手无策”：

- **模态缺失**：现有Deep Research系统仅支持纯文本网页，无法处理PDF、论文、财报中的**图表、表格、公式**
- **结构破坏**：简单OCR将文档转为纯文本，丢失**布局信息**（如表格结构、图表标题）
- **检索粗暴**：单轮检索+固定粒度，无法适应“先概览后精读”的人类研究习惯



如图1所示，一个真实的研究场景可能需要：**跨3个文档→整合文本+表格+图片→回答多跳问题**。这正是Doc-Researcher要解决的挑战！

三位一体的解决方案

1 深度多模态解析（Deep Multimodal Parsing）

- **布局感知**：用MinerU检测文档元素（文本段、表格、图表、公式），保留**边界框坐标**
- **智能分块**：按章节合并文本，生成**4级粒度**（chunk/page/full/summary）




Figure 5: The overview of layout-aware chunking process and multimodal-to-text transcription.

布局感知的chunk

- **模态转录**：表格/图表用VLM生成描述，公式转LaTeX，实现**一次解析，多次复用**




图5：布局感知分块流程

2 系统级检索架构 (Systematic Retrieval)

	Model	Parameter	Embed type	Embed dimension	doc	M4DocBench page	layout	MMDocIR page	layout
Recall@k = 10	Text								
	BM25	-	-	-	51.5 / 59.3	22.1 / 25.6	15.8 / 17.1	60.0 / 65.0	45.1 / 48.8
	E5	0.34B	dense	1,024	65.7 / 75.4	29.9 / 31.8	18.0 / 18.0	54.4 / 61.3	38.0 / 44.8
	BGE-M3	0.56B	dense	1,024	75.4 / 81.4	33.3 / 40.0	19.2 / 20.8	58.0 / 61.9	41.3 / 44.9
	Qwen3-embedding	0.60B	dense	1,024	73.6 / 78.8	34.6 / 40.6	20.1 / 23.5	58.6 / 62.6	42.6 / 45.6
	Multi-reranking*	1.5B	hybrid	-	78.7 / 80.3	39.2 / 40.9	23.1 / 21.1	65.5 / 66.7	48.6 / 49.4
	Vision								
	DSE _{wiki-ss}	4.15B	dense	3,072	34.8 / 42.4	11.1 / 11.7	-	68.4 / 68.7	-
	ColPali	2.92B	multi	N _{tok} ×128	47.7 / 50.0	18.1 / 17.9	-	75.4 / 73.9	-
	ColQwen	2.21B	multi	N _{tok} ×128	49.8 / 55.8	25.5 / 24.2	-	77.4 / 75.4	-
Recall@k = 15	Text								
	BM25	-	-	-	58.1 / 66.3	28.0 / 32.6	20.3 / 22.9	62.4 / 68.0	46.8 / 52.2
	E5	0.34B	dense	1,024	75.4 / 81.9	35.3 / 41.7	22.1 / 25.2	58.0 / 64.4	41.2 / 48.0
	BGE-M3	0.56B	dense	1,024	83.3 / 87.6	41.2 / 46.8	23.8 / 24.9	61.4 / 64.8	44.4 / 47.9
	Qwen3-embedding	0.60B	dense	1,024	81.1 / 86.8	42.1 / 49.9	25.4 / 27.4	61.4 / 65.3	45.2 / 48.3
	Multi-reranking*	1.5B	hybrid	-	83.6 / 87.2	44.8 / 49.4	27.4 / 27.9	67.9 / 70.1	51.0 / 53.0
	Vision								
	DSE _{wiki-ss}	4.15B	dense	3,072	45.2 / 53.9	18.1 / 18.5	-	78.0 / 78.5	-
	ColPali	2.92B	multi	N _{tok} ×128	55.7 / 61.7	24.7 / 24.9	-	82.0 / 80.9	-
	ColQwen	2.21B	multi	N _{tok} ×128	60.6 / 69.4	33.8 / 33.3	-	83.1 / 82.9	-
Recall@k = 20	Text								
	BM25	-	-	-	61.3 / 69.3	30.2 / 36.3	22.1 / 24.8	64.5 / 65.3	48.9 / 49.5
	E5	0.34B	dense	1,024	79.4 / 85.1	39.4 / 47.5	25.6 / 29.0	60.1 / 66.4	43.3 / 49.7
	BGE-M3	0.56B	dense	1,024	86.6 / 89.9	46.8 / 52.3	27.3 / 28.7	62.8 / 67.0	45.5 / 49.8
	Qwen3-embedding	0.60B	dense	1,024	84.9 / 90.6	47.2 / 56.0	30.5 / 30.4	63.5 / 66.9	47.0 / 50.2
	Multi-reranking*	1.5B	hybrid	-	87.8 / 90.3	50.6 / 56.3	31.9 / 32.3	70.1 / 71.7	53.5 / 54.9
	Vision								
	DSE _{wiki-ss}	4.15B	dense	3,072	52.5 / 59.5	23.3 / 23.5	-	83.1 / 83.8	-
	ColPali	2.92B	multi	N _{tok} ×128	61.5 / 67.8	29.5 / 30.0	-	86.0 / 85.6	-
	ColQwen	2.21B	multi	N _{tok} ×128	67.8 / 77.0	40.0 / 40.9	-	86.8 / 86.9	-


对比10种检索器后，发现：

- **文本检索**：适合密集文本，但丢失视觉语义（如折线图趋势）
- **视觉检索**：直接编码页面截图，保留图表信息，但计算成本高
- **混合检索**：文本块+视觉块双编码，在M4DocBench上提升8-12%召回率

检索范式	代表模型	优势场景	计算成本
文本检索	Qwen3-Embedding	合同、论文正文	低 (0.6B参数)
视觉检索	ColPali/Jina-VL	财报图表、幻灯片	高 (>3B参数)
混合检索	Doc-Researcher	复杂多模态文档	中等

3 多智能体研究流程 (Multi-Agent Workflow)

- **Planner**：像人类研究员一样先筛选相关文档（减少60-80%搜索空间），再动态选择粒度（summary→chunk→page）
- **Searcher & Refiner**：迭代执行“检索-精炼”循环，支持多跳推理（如先找“Q3营收”→再对比“同比增长”）
- **Reporter**：生成图文交织的答案，直接嵌入关键图表作为证据






图2：Doc-Researcher系统架构

全面碾压现有方案

🏆 M4DocBench：首个“四多”基准




Figure 4: Demonstration of two typical annotations of M4DocBench. Note that they are simplified for brevity.

M4DocBench标注示例

为公平评测，构建了M4DocBench：

- 多跳 (Multi-hop)：158个问题平均需3.8个文档证据链
- 多模态 (Multi-modal)：112个问题需文本+表格+图片
- 多文档 (Multi-document)：平均每题12.7个文档（最多42个）
- 多轮 (Multi-turn)：58个问题需结合对话历史

维度	M4DocBench	现有最佳基准
平均文档数	12.7	1-2
证据页数	7.0页	1.2页
标注细粒度	14.8个布局框	无

📈 性能对比：3.4倍提升！

在M4DocBench上，Doc-Researcher以**50.6%准确率**登顶，远超：

- **最强基线**（MDocAgent）：15.8% → **+34.8%**
- **长文本模型**（DeepSeek-R1）：31.7% → **+18.9%**
- **纯视觉RAG**（M3DocRAG）：7.0% → **+43.6%**

图3：迭代搜索深度对性能的影响

从实验室到产业界

场景	传统方案痛点	Doc-Researcher优势
金融研报分析	手工整理图表数据	自动提取图表+跨报告对比
法律合同审查	遗漏附件中的关键条款	联合解析正文+附件+附图
医学文献调研	无法结合CT图像与文字	整合影像+病历+论文
教育资料准备	幻灯片与讲义分离	统一检索PPT+PDF+教材

<https://arxiv.org/html/2510.21603>
研究机构：华为技术有限公司
Doc-Researcher: A Unified System for Multimodal Document Parsing and Deep Research

推荐阅读

- 动手设计AI Agents：（编排、记忆、插件、workflow、协作）
- 一篇92页大模型Vibe Coding技术全面综述
- 快手开源多模态Keye-VL-1.5-8B，本地视觉Agent有救了
- 一篇最新自演化AI Agents全新范式系统性综述

每天一篇大模型Paper来锻炼我们的思维~已经读到这了，不妨点个👍、❤️、🔗三连，加个星标⭐，不迷路哦~

[上一篇](#)
Claude Agent Skills: 从第一性原理深入剖析

[下一篇](#)
它来了! Context Engineering 2.0