

DeepSeek_R1技术报告解析

原创 katherina 机器人的脑电波 2025年2月11日 11:47 重庆



DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

DeepSeek-AI

research@deepseek.com

公众号 · 机器人的脑电波

以下项目地址汇总：

DeepSeek-R1:

<https://github.com/deepseek-ai/DeepSeek-R1>

HuggingFace:


<https://github.com/huggingface/open-r1>

摘要

本文介绍了第一代推理模型：DeepSeek-R1-Zero和DeepSeek-R1。DeepSeek-R1-Zero通过大规模强化学习（RL）训练而成，未经过监督微调（SFT）的预训练步骤，展示了显著的推理能力。通过RL，DeepSeek-R1-Zero自然地出现了许多强大而有趣的推理行为。

然而，它也面临着可读性差和语言混杂等挑战。为了解决这些问题并进一步提升推理性能，DeepSeek-R1被引入，在RL之前结合多阶段训练和冷启动数据。DeepSeek-R1在推理任务上的性能与OpenAI-o1-1217相当。

为了支持研究社区，DeepSeek-R1-Zero、DeepSeek-R1以及从DeepSeek-R1中基于Qwen和Llama提取出的六个密集模型（1.5B，7B，8B，14B，32B，70B）被开源。



方法

概述

本文旨在展示即使不使用监督微调（SFT）作为冷启动，大规模强化学习（RL）也能显著提高模型的推理能力。此外，在包含少量冷启动数据的情况下，性能可以进一步提升。

在下文中将介绍：

- (1) 直接将RL应用于基础模型的DeepSeek-R1-Zero，未使用任何SFT数据，
- (2) 从通过成千上万个长链推理（CoT）示例微调的检查点开始应用RL的DeepSeek-R1，
- (3) 将DeepSeek-R1的推理能力扩展到小型密集模型。

DeepSeek-R1-Zero：基础模型上的强化学习

强化学习已证明在推理任务中具有显著的效果，尽管之前的工作严重依赖于时间密集型的监督数据。在本节中，将探讨大语言模型（LLM）在缺乏任何监督数据情况下如何发展推理能力。首先简要概述我们的RL算法，接下来将呈现一些令人兴奋的结果，希望这能为研究社区提供有价值的见解。

强化学习算法

我们采用**群体相对策略优化（GRPO）**（Shao et al., 2024），以节省RL的训练成本。这种方法放弃了通常与策略模型大小相同的评价模型，而是从组得分中估计基线。具体而言，对于每个问题 q ，GRPO从旧策略中采样一组输出 $\{o_1, o_2, \dots, o_g\}$ ，然后通过最大化以下目标来优化策略模型：

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)]$$

$$\frac{1}{G} \sum_{i=1}^G \left(\min \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)}, 1 - \varepsilon, 1 + \varepsilon \right) A_i \right) - \beta \mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) \right),$$

$$\mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) = \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - \log \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - 1,$$

其中， ε 和 β 是超参数，而 A 是优势，通过与每组输出相对应的一组奖励（ $r_1, r_2, \dots, r_g$ ）计算得出。

奖励建模

奖励是训练信号的来源，决定了强化学习（RL）的优化方向。在训练 DeepSeek-R1-Zero 时，采用了基于规则的奖励系统，这个系统主要由两种奖励组成：

- **准确性奖励**
：准确性奖励模型用于评估模型的回答是否正确。例如，在具有确定性结果的数学问题中，要求模型以指定格式（例如，用框标出）提供最终答案，以便进行可靠的基于规则的正确性验证。同样地，对于 LeetCode 问题，可以使用编译器基于预定义测试用例生成反馈。
- **格式奖励**
：除了准确性奖励，我们还引入了格式奖励模型，要求模型将其推理过程放在 `<think>` 和 `</think>` 标签之间。

在开发 DeepSeek-R1-Zero 时，没有使用基于神经网络的奖励模型，因为这种模型在大规模强化学习过程中可能存在奖励欺骗的问题，并且重新训练奖励模型需要额外的训练资源，从而复杂化整个训练流程。

训练模板

为了训练 DeepSeek-R1-Zero，设计了一个简单的模板，引导基础模型遵循指定的指令。如表所示，模板要求 DeepSeek-R1-Zero 先生成一个推理过程，然后再提供最终答案。训练时特意将限制设置为结构化格式，而不是内容特定的偏向（如强制要求反思性推理或鼓励特定的解决策略），以确保可以准确观察模型在 RL 过程中的自然发展。

A conversation between User and Assistant. The user asks a question, and the Assistant solves it. The assistant first thinks about the reasoning process in the mind and then provides the user with the answer. The reasoning process and answer are enclosed within `<think>` `</think>` and `<answer>` `</answer>` tags, respectively, i.e., `<think>` reasoning process here `</think>` `<answer>` answer here `</answer>`. User: **prompt**. Assistant:

Table 1 | Template for DeepSeek-R1-Zero. **prompt** will be replaced with the specific reasoning question during training.


DeepSeek-R1-Zero 的性能、自我进化过程和灵光乍现

在 AIME 2024 基准测试中，随着 RL 训练的进行，DeepSeek-R1-Zero 显示出稳定且持续的性能提升。其平均通过率（Pass@1）从初始的 15.6% 显著提高到 **71.0%**，达到了与 OpenAI-o1-0912 性能相当的水平。这一重大进步表明，强化学习算法在优化模型性能方面具有显著效果。

Model	AIME 2024		MATH-500	GPQA Diamond	LiveCode Bench	CodeForces
	pass@1	cons@64	pass@1	pass@1	pass@1	rating
OpenAI-o1-mini	63.6	80.0	90.0	60.0	53.8	1820
OpenAI-o1-0912	74.4	83.3	94.8	77.3	63.4	1843
DeepSeek-R1-Zero	71.0	86.7	95.9	73.3	50.0	1444

Table 2 | Comparison of DeepSeek-R1-Zero and OpenAI o1 models on reasoning-related benchmarks.

通过将**多数投票（majority voting）**应用于AIME基准测试，可以进一步增强性能。例如，采用多数投票后，DeepSeek-R1-Zero的性能从71.0%提升到**86.7%**，超过了OpenAI-o1-0912的表现。该模型强大的基础能力和在推理任务中进一步提高的潜力得到了充分证明。



自我进化过程

DeepSeek-R1-Zero的自我进化过程展示了RL如何推动模型自发提高推理能力。从基础模型开始直接通过RL训练，可以在不依赖监督微调阶段的情况下监控模型的进展。这种方法提供了一个清晰的视角，观察模型在处理复杂推理任务方面的逐步演进。

如下图所示，在RL过程中，DeepSeek-R1-Zero产生的响应长度显示出持续改善。这种改善并非外部调整的结果，而是模型内在发展的体现。通过构建数百到数千的推理标记，DeepSeek-R1-Zero自然学会了通过延长测试时间计算来解决日益复杂的推理任务，从而以更深层次探索并优化其推理过程。

灵光乍现

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a + x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a + x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a + x}})^2 = x^2 \implies a - \sqrt{a + x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = a + x \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a + x}} = x$$

First, let's square both sides:

$$a - \sqrt{a + x} = x^2 \implies \sqrt{a + x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

...

Table 3 | An interesting “aha moment” of an intermediate version of DeepSeek-R1-Zero. The model learns to rethink using an anthropomorphic tone. This is also an aha moment for us, allowing us to witness the power and beauty of reinforcement learning.

训练过程中，DeepSeek-R1-Zero 表现出一个特别有趣的现象——“灵光乍现”（Aha Moment）。这个现象表现在模型的一个中期版本中。在这一阶段，DeepSeek-R1-Zero 学会了通过重新评估其初始方法，为一个问题分配更多的思考时间。这种行为不仅是模型推理能力逐步增强的佐证，也是挖掘强化学习意外产物的一个生动例子。

这一现象不仅是模型的“灵光乍现”，也是研究者观察模型行为的一个亮点。它强调了强化学习的潜力——无需明确教授模型如何解决问题，只需提供正确的激励，模型便能自主开发高级问题解决策略。这样的“灵光乍现”强有力地提醒了我们RL在开启人工系统新层次智能方面的潜能，为未来更多自主和更具适应性的模型铺平了道路。

DeepSeek-R1-Zero的缺陷

尽管DeepSeek-R1-Zero展示了强大的推理能力，并自发开发出意外而强大的推理行为，但它仍然存在挑战。例如，DeepSeek-R1-Zero面临可读性差和语言混杂等问题。为了解决这些问题并与公开社区共享更加可读的推理过程，我们探索了DeepSeek-R1，它引入了基于人类友好的冷启动数据的RL方法。

DeepSeek-R1：带有冷启动的强化学习

受到DeepSeek-R1-Zero优异表现的启发，两个问题随之而来：

1. 是否可以通过引入少量高质量数据作为冷启动，提高模型性能？
2. 如何训练一个用户友好型模型，不仅能生成清晰连贯的推理链（CoT），还能展示出强大的通用能力？

为了解决这些问题，设计了一条训练DeepSeek-R1的管道，该管道包括以下四个阶段。

冷启动

与DeepSeek-R1-Zero不同，为了避免RL训练初期从基础模型开始的不稳定，我们为DeepSeek-R1构建并收集了一小部分长CoT数据，用以微调模型为初始RL参与者。冷启动数据的优势包括：

- 可读性提升

: DeepSeek-R1-Zero的内容往往不适合阅读，例如混合多种语言或缺乏清晰格式。在创建冷启动数据时设计了一个可读性较强的模式，包括在每个响应末尾提供摘要，并过滤掉不适合阅读的响应。

- 性能潜力

: 融入人类经验设计冷启动数据模式，我们观察到较DeepSeek-R1-Zero明显更好的表现。

面向推理的强化学习

在使用冷启动数据微调DeepSeek-V3-Base后，采用与DeepSeek-R1-Zero相同的强化学习训练过程，提升模型在诸如代码、数学、科学和逻辑推理等需要明确解决方案的任务中的能力。此外，引入语言一致性奖励以解决语言混杂问题。最终，结合推理任务的准确性奖励和语言一致性奖励，形成最终奖励，进行训练直到收敛。

拒绝采样与监督微调

当面向推理的RL达到收敛时，使用所得的检查点收集监督微调（SFT）数据，用于后续训练阶段。通过拒绝采样，我们过滤生成质量较低的数据，最终收集了约60万样本的推理相关训练数据，还收集了约20万条非推理相关样本。最终使用约80万条样本对DeepSeek-V3-Base进行了两轮微调。

全场景强化学习

为进一步使模型符合人类偏好，实施了第二阶段的强化学习，以提高模型的有用性和无害性，同时优化其推理能力。特别是，使用奖励信号和多样的提示分布训练模型。在推理数据方面，遵循DeepSeek-R1-Zero中所述的方法，利用基于规则的奖励在数学、代码和逻辑推理领域指导学习过程。对于一般数据，使用奖励模型来捕捉复杂和微妙场景中的人类偏好。

在构建提示时，针对有用性，专注于最终总结，确保评估强调对用户有用和相关的回应，而尽量减少对基本推理过程的干扰。对于无害性，对模型的整个响应进行评估，包括推理过程和总结，以识别并缓解生成过程中的潜在风险、偏见或有害内容。最终，奖励信号和多样数据分布的融合使得我们能够训练出一个在推理中表现出色，同时优先考虑有用性和无害性的模型。

蒸馏：赋予小模型推理能力

为了使更高效的小模型具备像DeepSeek-R1一样的推理能力，我们直接使用从DeepSeek-R1筛选出的80万样本对Qwen和Llama等开源模型进行了微调。研究表明这种简单的蒸馏方法显著增强了小模型的推理能力。这里使用的基础模型包括Qwen2.5-Math-1.5B、Qwen2.5-Math-7B、Qwen2.5-14B、Qwen2.5-32B、Llama-3.1-8B和Llama-3.3-70B-Instruct。选择Llama-3.3是因为其推理能力略优于Llama-3.1。

对于蒸馏模型，我们仅应用监督微调（SFT），而未加入RL阶段，尽管加入RL可大幅提升模型性能。我们的主要目标是展示蒸馏技术的有效性，RL阶段的探索留给更广泛的研究社区。

实验

基准测试

模型在MMLU、MMLU-Redux、MMLU-Pro、C-Eval、CMMLU、IFEval、FRAMES、

GPQA Diamond、SimpleQA、C-SimpleQA、SWE-Bench Verified、Aider 1、LiveCodeBench等多个基准测试集上进行评估。除标准基准外，还在开放性生成任务上使用大型语言模型（LLM）作为评判，具体遵循AlpacaEval 2.0和Arena-Hard的原始配置。

评估提示

在DeepSeek-V3的设置中，使用simple-evals框架的提示对标准基准（如MMLU、DROP、GPQA Diamond、SimpleQA）进行评估。对MMLU-Redux采用零射情况的Zero-Eval提示格式。对MMLU-Pro、C-Eval和CLUE-WSC，由于原始提示为少样本，略微修改提示为零样本设置。其他数据集遵循它们的原始评估协议，并使用创作者提供的默认提示。

基线对比

我们对多个强基线模型进行全面评估，包括DeepSeek-V3、Claude-Sonnet-3.5-1022、GPT-4o-0513、OpenAI-o1-mini和OpenAI-o1-1217。对于蒸馏模型，亦与开源模型QwQ-32B-Preview进行对比。

评估设置

将最大生成长度设置为32,768个token。发现使用贪婪解码评估长输出推理模型会导致重复率增高和不同检查点间的显著差异。因此，默认使用非零温度的pass@k评估（即，使用温度为0.6和top-p值为0.95的采样来生成k，计算为每个响应的正确性）。

$$\text{pass@1} = \frac{1}{k} \sum_{i=1}^k p_i,$$

在以教育为导向的知识基准（如MMLU、MMLU-Pro、GPQA Diamond）上，DeepSeek-R1的表现优于DeepSeek-V3，这主要归因于在STEM相关问题上的准确性提高。这突显了推理模型在AI驱动搜索和数据分析任务中的潜力。在事实基准SimpleQA上，DeepSeek-R1同样表现出色。

Benchmark (Metric)		Claude-3.5- Sonnet-1022	GPT-4o 0513	DeepSeek V3	OpenAI o1-mini	OpenAI o1-1217	DeepSeek R1
	Architecture	-	-	MoE	-	-	MoE
	# Activated Params	-	-	37B	-	-	37B
	# Total Params	-	-	671B	-	-	671B
English	MMLU (Pass@1)	88.3	87.2	88.5	85.2	91.8	90.8
	MMLU-Redux (EM)	88.9	88.0	89.1	86.7	-	92.9
	MMLU-Pro (EM)	78.0	72.6	75.9	80.3	-	84.0
	DROP (3-shot F1)	88.3	83.7	91.6	83.9	90.2	92.2
	IF-Eval (Prompt Strict)	86.5	84.3	86.1	84.8	-	83.3
	GPQA Diamond (Pass@1)	65.0	49.9	59.1	60.0	75.7	71.5
	SimpleQA (Correct)	28.4	38.2	24.9	7.0	47.0	30.1
	FRAMES (Acc.)	72.5	80.5	73.3	76.9	-	82.5
	AlpacaEval2.0 (LC-winrate)	52.0	51.1	70.0	57.8	-	87.6
	ArenaHard (GPT-4-1106)	85.2	80.4	85.5	92.0	-	92.3
Code	LiveCodeBench (Pass@1-COT)	38.9	32.9	36.2	53.8	63.4	65.9
	Codeforces (Percentile)	20.3	23.6	58.7	93.4	96.6	96.3
	Codeforces (Rating)	717	759	1134	1820	2061	2029
	SWE Verified (Resolved)	50.8	38.8	42.0	41.6	48.9	49.2
	Aider-Polyglot (Acc.)	45.3	16.0	49.6	32.9	61.7	53.3
Math	AIME 2024 (Pass@1)	16.0	9.3	39.2	63.6	79.2	79.8
	MATH-500 (Pass@1)	78.3	74.6	90.2	90.0	96.4	97.3
	CNMO 2024 (Pass@1)	13.1	10.8	43.2	67.6	-	78.8
Chinese	CLUEWSC (EM)	85.4	87.9	90.9	89.9	-	92.8
	C-Eval (EM)	76.7	76.0	86.5	68.9	-	91.8
	C-SimpleQA (Correct)	55.4	58.7	68.0	40.3	-	63.7

Table 4 | Comparison between DeepSeek-R1 and other representative models. 公众号：机器人的脑电波

在数学任务上，DeepSeek-R1的表现与OpenAI-o1-1217相当，大幅超越其他模型。类似的趋势也出现在LiveCodeBench和Codeforces等代码算法任务中。在工程相关任务上，DeepSeek-R1目前表现略逊于Aider，但在未来版本中相关数据量有限的情况下，预计性能将有改善。

简单蒸馏DeepSeek-R1的输出，使得高效的DeepSeek-R1-7B在全面上优于非推理模型，如GPT-4o-0513。DeepSeek-R1-14B在所有评估指标上超过了QwQ-32B-Preview，而DeepSeek-R1-32B和DeepSeek-R1-70B在多数基准上显著超越o1-mini。

Model	AIME 2024		MATH-500	GPQA Diamond	LiveCode Bench	CodeForces
	pass@1	cons@64	pass@1	pass@1	pass@1	rating
GPT-4o-0513	9.3	13.4	74.6	49.9	32.9	759
Claude-3.5-Sonnet-1022	16.0	26.7	78.3	65.0	38.9	717
OpenAI-o1-mini	63.6	80.0	90.0	60.0	53.8	1820
QwQ-32B-Preview	50.0	60.0	90.6	54.5	41.9	1316
DeepSeek-R1-Distill-Qwen-1.5B	28.9	52.7	83.9	33.8	16.9	954
DeepSeek-R1-Distill-Qwen-7B	55.5	83.3	92.8	49.1	37.6	1189
DeepSeek-R1-Distill-Qwen-14B	69.7	80.0	93.9	59.1	53.1	1481
DeepSeek-R1-Distill-Qwen-32B	72.6	83.3	94.3	62.1	57.2	1691
DeepSeek-R1-Distill-Llama-8B	50.4	80.0	89.1	49.0	39.6	1205
DeepSeek-R1-Distill-Llama-70B	70.0	86.7	94.5	65.2	57.5	1633

Table 5 | Comparison of DeepSeek-R1 distilled models and other comparable models on reasoning-related benchmarks. 公众号：机器人的脑电波

Model	AIME 2024		MATH-500	GPQA Diamond	LiveCodeBench
	pass@1	cons@64	pass@1	pass@1	pass@1
QwQ-32B-Preview	50.0	60.0	90.6	54.5	41.9
DeepSeek-R1-Zero-Qwen-32B	47.0	60.0	91.6	55.0	40.2
DeepSeek-R1-Distill-Qwen-32B	72.6	83.3	94.3	62.1	57.2

Table 6 | Comparison of distilled and RL Models on Reasoning-Related Benchmarks.

总结

DeepSeek-R1 通过强化学习显著提升了模型的推理能力，并在多项任务上取得了与 OpenAI-o1-1217 相当的性能。通过模型蒸馏，DeepSeek-R1 的推理能力被成功转移到小型密集模型中，取得了令人鼓舞的结果。未来，研究团队计划在通用能力、语言混合问题、提示工程和软件工程任务等方面进行进一步研究，以进一步提升 DeepSeek-R1 的性能和应用范围。

ai 20 llm 18 rl 1

ai · 目录

上一篇 · 阿里&上交RAGDiffusion：从模特照片生成高保真服装平铺图！