

QLoRA：一种高效LLMs微调方法，48G内存可调LLaMA-65B（开源）

原创 ShuYini AINLPer 2023年5月25日 21:01 上海

点击上方“[AINLPer](#)”，设为星标
更多干货，第一时间送达



AINLPer

一个专注大模型AIGC方向的公众号。每日分享大模型(LLM)技术、智能Agent，国内外...
457篇原创内容

公众号

引言

QLoRA是一种「**高效的微调方法**」，可以在保持完整的16位微调任务性能的情况下，将内存使用降低到足以「**在单个48GB GPU上微调650亿参数模型**」。QLoRA通过冻结的4位量化预训练语言模型向低秩适配器(LoRA)反向传播梯度。作者公布了他们训练的系列模型Guanaco，与之前公开发布的所有模型相比，在Vicuna基准测试中表现更好，「**只需要在单个GPU上微调24小时就能达到ChatGPT性能水平的99.3%**」。

QLoRA: Efficient Finetuning of Quantized LLMs

Paper: <https://arxiv.org/pdf/2305.14314.pdf>

Code: <https://github.com/artidoro/qlora>

背景介绍


大型语言模型（LLM）调优是提高其性能的最有效的方式，它允许我们添加所需的内容或删除不需要的内容。但是，「**微调非常大的模型的成本过高；对650亿参数的LLaMA模型进行进行16位微调需要超过780GB的GPU内存**」。虽然最近的量化方法可以减少LLM的内存占用量，但是这些技术仅适用于推理，并不适合在训练过程中使用。

本文首次证明可以在不降低任何性能的情况下微调量化4-bit模型。提出了一种高效的模型训练方法QLoRA，该方法使用一种新颖的高精度技术将预训练模型量化为4-bit，然后添加一小组可学习的低秩适配器权重（Low-rank Adapter weights），这些权重通过量化权重的反向传播梯度进行调优。

与16-bit完全微调基线相比，QLoRA 将微调65B参数模型的平均内存需求从 >780GB降低到 <48GB，并且不会降低模型预测性能。「**这标志着LLM调优发生了重大转变，大模型的调优并非遥不可及**」：现在是迄今为止最大的公开可用模型，可在单个 GPU 上进行微调。作者使用 QLoRA，训练了 Guanaco 系列模型，在单个消费类 GPU 上训练不到12小时，模型在 Vicuna 基准测试中达到了 ChatGPT 性能水平的97.8%；在单个专业级GPU上训练了不到24小时，模型在 Vicuna 基准测试上达到了 ChatGPT 性能水平的99.3%；在部署过程中，最小的 Guanaco 模型（7B 参数）仅需要 5 GB 的内存，并且在 Vicuna 基准测试中比 26 GB 的 Alpaca模型高出20个百分点以上。

QLoRA微调方法

QLoRA是一种针对深度神经网络的低精度量化和微调技术，能够实现高保真的4位微调。「它采用了两种技术——4位NormalFloat (NF4)量化和Double Quantization」。同时，引入了Paged Optimizers，它可以避免梯度检查点操作时内存爆满导致的内存错误。QLoRA包含一种低精度存储数据类型（通常为4-bit）和一种计算数据类型（通常为BFloat16）。在实践中，QLoRA权重张量使用时，需要将张量去量化为BFloat16，然后在16位计算精度下进行矩阵乘法运算。




QLoRA包含两个组件：4-bit NormalFloat量化和Double Quantization。其中：4-bit NormalFloat数据类型是基于Quantile Quantization技术开发的，通过估计输入张量的分位数来保证每个量化区间分配相等的值。Double Quantization是将额外的量化常数进行量化以减小内存开销的过程。

为了防止梯度检查点所引起的内存波动导致的内存不足错误，QLoRA引入了Paged Optimizers技术。这种技术使用了NVIDIA统一内存的特性，实现了CPU和GPU之间自动的页面转换，在GPU内存不足的情况下自动将优化器状态转移到CPU内存。QLoRA通常使用4位NormalFloat作为存储数据类型和16位BrainFloat作为计算数据类型，在计算梯度时只对LoRA的参数计算梯度。

QLoRA对比标准FT

QLoRA 是否能像标准模型 Fine-tuning 一样有效呢？作者分析了 QLoRA 的各个组成部分，包括 NormalFloat4 相对于标准 Float4 的影响，以及对比了QLoRA的16-bit Adapter FT和标准FT。



在语言模型和零样本任务的评估中，「4-bit NormalFloat数据类型(NF4)表现出更好的性能，优于4-bit浮点数(FP4)」。如上表所示：研究采用了不同类型的量化LLMs（OPT，BLOOM，Pythia，LLaMA）以及不同大小（125M到65B），比较NF4、FP4和Int4的性能，并发现NF4能够显著提升性能，双重量化可以减少内存占用同时不影响性能。

Table 3: Experiments comparing 16-bit BrainFloat (BF16), 8-bit Integer (Int8), 4-bit Float (FP4), and 4-bit NormalFloat (NF4) on GLUE and Super-NaturalInstructions. QLoRA replicates 16-bit LoRA and full-finetuning.

Dataset Model	GLUE (Acc.) RoBERTa-large	Super-NaturalInstructions (RougeL)				
		T5-80M	T5-250M	T5-780M	T5-3B	T5-11B
BF16	88.6	40.1	42.1	48.0	54.3	62.0
BF16 replication	88.6	40.0	42.2	47.3	54.9	-
LoRA BF16	88.8	40.5	42.6	47.1	55.4	60.7
QLoRA Int8	88.8	40.4	42.9	45.4	56.5	60.7
QLoRA FP4	88.6	40.3	42.4	47.5	55.6	60.9
QLoRA NF4 + DQ	-	40.4	42.7	47.7	55.3	60.9

比较RoBERTa和T5模型在GLUE和Super-NaturalInstructions数据集上结果表明：「无论是使用16位、8位还是4位的适配器方法，都能够复制全16位微调的基准的性能」。这说明，尽管量化过程中会存在性能损失，但通过适配器微调，完全可以恢复这些性能。

Guanaco系列模型

作者使用4-bitQLoRA量化技术对不同规模参数模型进行调优，并与16位精度调优进行对比。结果表明，使用双量化的NF4可以匹配BFloat16性能，并且FP4调优结果都要比两者低一个百分点。如下图所示：

Table 4: Mean 5-shot MMLU test accuracy for LLaMA 7-65B models finetuned with adapters on Alpaca and FLAN v2 for different data types. Overall, NF4 with double quantization (DQ) matches BFloat16 performance, while FP4 is consistently one percentage point behind both.

LLaMA Size Dataset	Mean 5-shot MMLU Accuracy								Mean
	7B		13B		33B		65B		
	Alpaca	FLAN v2	Alpaca	FLAN v2	Alpaca	FLAN v2	Alpaca	FLAN v2	
BFloat16	38.4	45.6	47.2	50.6	57.7	60.5	61.8	62.5	53.0
Float4	37.2	44.0	47.3	50.0	55.9	58.5	61.3	63.3	52.2
NFloat4 + DQ	39.0	44.5	47.5	50.7	57.3	59.2	61.8	63.9	53.1

基于QLoRA调优方法，作者对OASST1进行调优得到系列模型Guanaco，并于当前主流模型进行对比，在Vicuna基准上的结果如下图所示，可以发现「：Guanaco-65B是仅次于GPT-4的表现最优秀的模型，相对于ChatGPT的表现达到了99.3%，最小的Guanaco模型

（7B参数）仅需要5GB的内存，并且在Vicuna基准测试中比26GB的Alpaca模型高出20个百分点以上」。

Table 6: Zero-shot Vicuna benchmark scores as a percentage of the score obtained by ChatGPT evaluated by GPT-4. We see that OASST1 models perform close to ChatGPT despite being trained on a very small dataset and having a fraction of the memory requirement of baseline models.

Model / Dataset	Params	Model bits	Memory	ChatGPT vs Sys	Sys vs ChatGPT	Mean	95% CI
GPT-4	-	-	-	119.4%	110.1%	114.5%	2.6%
Bard	-	-	-	93.2%	96.4%	94.8%	4.1%
Guanaco	65B	4-bit	41 GB	96.7%	101.9%	99.3%	4.4%
Alpaca	65B	4-bit	41 GB	63.0%	77.9%	70.7%	4.3%
FLAN v2	65B	4-bit	41 GB	37.0%	59.6%	48.4%	4.6%
Guanaco	33B	4-bit	21 GB	96.5%	99.2%	97.8%	4.4%
Open Assistant	33B	16-bit	66 GB	91.2%	98.7%	94.9%	4.5%
Alpaca	33B	4-bit	21 GB	67.2%	79.7%	73.6%	4.2%
FLAN v2	33B	4-bit	21 GB	26.3%	49.7%	38.0%	3.9%
Vicuna	13B	16-bit	26 GB	91.2%	98.7%	94.9%	4.5%
Guanaco	13B	4-bit	10 GB	87.3%	93.4%	90.4%	5.2%
Alpaca	13B	4-bit	10 GB	63.8%	76.7%	69.4%	4.2%
HH-RLHF	13B	4-bit	10 GB	55.5%	69.1%	62.5%	4.7%
Unnatural Instr.	13B	4-bit	10 GB	50.6%	69.8%	60.5%	4.2%
Chip2	13B	4-bit	10 GB	49.2%	69.3%	59.5%	4.7%
Longform	13B	4-bit	10 GB	44.9%	62.0%	53.6%	5.2%
Self-Instruct	13B	4-bit	10 GB	38.0%	60.5%	49.1%	4.6%
FLAN v2	13B	4-bit	10 GB	32.4%	61.2%	47.0%	3.6%
Guanaco	7B	4-bit	5 GB	84.1%	89.8%	87.0%	5.4%
Alpaca	7B	4-bit	5 GB	57.3%	71.2%	64.4%	5.0%
FLAN v2	7B	4-bit	5 GB	33.3%	56.1%	44.8%	4.0%

本文评价

该阐述了QLoRA方法可以使用4位基础模型和低秩适配器达到16位全精度微调的效果，并对聊天机器人的性能进行了评估。但该方法未在33B和65B规模上比较全精度微调的结果，并且使用的基准数据集可能限制了评价的泛化性。

推荐阅读

- [1]斯坦福发布AlpacaFarm，RLHF人工成本降低45倍！
- [2]Meta最新模型LIMA，没有RLHF，远胜Alpaca！！
- [3]强！中科院调研了27个大模型，并指出5个重要挑战
- [4]三种Prompt方法大幅提升大模型LLMs推理能力！
- [5]一文了解大型语言模型的上下文学习能力（ICL）
- [6]MPT-7B：可商用的开源模型，效果堪比LLaMA-7B

[点击下方链接](#)  关注我们



AINLPer

一个专注大模型AIGC方向的公众号。每日分享大模型(LLM)技术、智能Agent，国内外精...
457篇原创内容

公众号

「资料整理不易，点个赞、再看吧」

上一篇

刚刚！斯坦福发布 AlpacaFarm (羊驼农场),
可将RLHF人工成本降低45倍！（开源）

下一篇

QLoRA：高效LLMs微调方法，48GB微调模
型，可达ChatGPT性能水平的99.3%