

一、产品

1.1 宙斯搜索问答平台

定位：通用型 RAG 搜索问答基础设施

搜索能力

- 文档解析：
 - 支持 10+ 种格式（PDF、Word、Excel、PPT、Markdown、HTML 等）
- 文本切片：
 - 基于规则（标题、段落、固定长度）
 - 基于视觉模型（LayoutLM 等识别文档结构）
- 索引构建：
 - 向量索引：稀疏向量 (SPLADE) + 稠密向量 (BGE/M3) + Late Chunking
 - 文本索引：BM25/倒排索引
 - 知识图谱索引：实体关系三元组
- 排序：
 - 多路召回融合
 - RRF (Reciprocal Rank Fusion)
 - Reranker 重排序

问答能力

- 多租户管理
- 大模型配置（支持主流 LLM 接入）
- 知识库管理
- 限制：不支持流程编排

技术亮点

- 跨语言检索精度提升 **2%**（通过多语言向量 + 翻译）
- 支持 Global（主题级）和 Local（详情级）双层召回

1.2 统一搜索员工askbob

定位：定制化场景搜索解决方案

核心能力：


- 多数据源整合（数据库、文档、API 等）
- 深度语义理解（意图识别、实体识别、词权重）
- 场景化查询改写(通用改写+基本法+联系人改写等)
- 多路召回策略（向量 + 文本 + [图谱]）
- 多层次排序（粗排 → 精排 → 多样性重排）
- 规则干预与业务定制
- 埋点分析与运营系统

应用场景：人事搜索、it知识库、公文新闻检索等垂直场景

二、系统设计


2.1 宙斯RAG 流程


在线处理 → 离线处理 →



2.1.1 RAPTOR 层次化索引

- layoutLM 段落布局切片
- 父子块关联 Chunk + Parent Document
- 生成摘要(摘要和切片索引)和假设性问题
- 无gmm聚类





优势：

- 支持不同粒度召回
- 父块召回后可下钻到子块
- 检索回答宏观问题（书籍类）

2.1.2 知识图谱构建(完善中)

用于通讯录，领导卡片和人事搜索问答领域

流程：

文档 → 实体抽取 → 关系抽取 → 实体链接 + 三元组存储 → 社区发现(leide)

应用：

- Global 类问题由社区描述直接回答
- 支持多跳推理 ($A \rightarrow B \rightarrow C$)

示例：


```
{
  "head": "张三",
  "relation": "任职于",
  "tail": "银行人事部"
}
```

2.1.3 Late Chunking 技术

传统方式：

长文本 → 切分为小段 → 分别编码 → 丢失全局信息

Late Chunking：



长文本 → 整体编码（保留全局信息）→ Pooling → 拆分小切片向量

优势：

- 捕捉跨段落的语义关联
- 适合长文档检索，解决文档级别的指代问题

2.1.4 混合向量索引

- 稠密向量：BGE-M3 / M3E（语义相似度）
- 稀疏向量：SPLADE（关键词增强）
- 效果：跨语言检索精度提升 2%

2.1.5. 查询理解 (Query Understanding)

- 意图识别：区分 Global（全局问题总结）vs Local（具体问题详情）

- Global 示例: "公司有哪些福利政策? "
- Local 示例: "我的年假还剩几天? "

- 实体识别:

- 提取关键信息 (人名、部门、时间、地点)

- 查询改写:

- 指代消解 ("它" → 具体对象)
- 信息补全 (补充隐含条件)
- 复杂问题拆解 (多跳问题分解)

2.1.6. 搜索召回 (Retrieval)

多路召回策略:

- 稠密向量召回 (语义相似度)
- 稀疏向量召回 (splade)
- BM25 文本召回
- 知识图谱召回 (实体关联)

排序融合:

- RRF (Reciprocal Rank Fusion) : $score(d) = \sum_{i=1}^n 1/(k + rank_i)$
- 加权融合: 向量 70% + BM25 30%
- cross-encoder

2.1.6 答案生成 (Generation)

挑战: Lost in the Middle 现象 (模型忽略中间内容)

解决方案:

- Context 重排序 (重要信息放两端)
- Context 压缩 (去除冗余)
- 分块生成 + 汇总

2.1.7 反思生成 (Reflection)


- 自检答案质量
- 低置信度时触发二次检索

- 多轮迭代优化

2.1.8 引文生成 (Citation)

基于ROUGE指标统计方式生成引文(后期版本大模型自己标注，速度快)

2.2 搜索流程



2.2.2. 问题改写 (Query Rewriting)

目标：将用户自然语言转换为高召回率的搜索查询

技术方案：NMT + 强化学习（详见第三章）

示例：

原始 query: "电脑登录不了，没法办公了"

↓

改写后: "办公电脑密码过期、账号解锁"

2.2.3 多样性排序

目标：多数源情况下排序多样性确保

技术方案：最大边界相关性，损失函数结合ndcg和相关性得分

三、核心算法优化


3.1 查询改写：NMT + 强化学习

技术方案来源：美团搜索 ~2020 年论文

核心思想

将搜索改写视为**神经机器翻译任务**：

- **源语言**：用户原始查询（通常不不规范、口语化）
- **目标语言**：高性能搜索查询（规范、易召回）
- **奖励信号**：搜索结果质量（点击率、排名、相关性）



技术架构：两阶段优化

第一阶段：监督学习预训练 (Supervised Learning)

模型结构：Encoder-Decoder (Transformer)

训练目标：最小化交叉熵损失

数据示例：

```
train_data = [
    ("寿改", "寿险改革"),
    ("拧毛巾", "清洗毛巾"),          # 负例：语义改变
    ("vpn 到期了怎么办", "vpn 申请链接"),
    ("电脑登录不了", "忘记密码"),
]
```

挑战：缺少 Decoder 预训练模型

- BERT/MacBERT 是 Encoder-only 架构
- 无法直接用于序列生成任务

第二阶段：强化学习微调 (Reinforcement Learning)

为什么需要 RL?

- 搜索指标 (nDCG、CTR) 不可导
- 无法通过反向传播直接优化
- RL 可通过策略梯度方法优化离散生成任务

RL 三要素:

1. 状态 (**State**): 原始查询 q + 已生成的词
2. 动作 (**Action**): 下一个词的选择
3. 奖励 (**Reward**): 搜索结果质量评估

奖励函数设计:

$$R = \alpha * \text{NDCG@10} + \beta * \text{MRR} + \gamma * \text{UserFeedback}$$

示例计算

if 点击量高 and 跳出率低:

 R = 1.0 # 优秀

elif 跳出率高 or 点击量低:

 R = -0.5 # 较差

else:

 R = 0.0 # 一般

联合损失函数:

$$L_{total} = \lambda * L_{RL} + (1 - \lambda) * L_{MLE}$$

作用: 防止 RL 导致模型坍塌 (生成病态但高分的查询)

实现挑战与解决方案

问题 1: 序列长度不一致

场景:

源序列: "vpn 到期" (2 个词)
目标序列: "vpn 续期申请" (4 个词)

传统 Seq2Seq 模型要求输入输出等长, 无法直接处理。

✅ 解决方案: Align with Insert 标记

步骤:

```
# 示例: "vpn 到期" → "vpn 续费申请"

# 步骤 1: 序列对齐
源: ["vpn", "到期"]
目标: ["vpn", "续", "期", "申请"]

# 步骤 2: 使用编辑距离算法建立对齐
对齐结果: [
    ("vpn", "vpn"),          # 保持
    ("<INS>", "续"),         # 插入
    ("<INS>", "期"),         # 插入
    ("到期", "申请")        # 替换
]

# 步骤 3: 构建新的输入序列
新输入: ["vpn", "<INS>", "<INS>", "到期"]
新目标: ["vpn", "续", "期", "申请"]
```

优势:

- 将变长生成问题转化为等长序列标注任务
- 可直接使用 BERT/MacBERT 等预训练模型
- 支持插入、删除、替换操作

数据格式:

```
{
  "input": ["vpn", "<INS>", "<INS>", "到期"],
  "labels": ["vpn", "续", "期", "申请"],
  "loss_mask": [0, 1, 1, 1] // 只有<INS>位置计算损失
}
```

训练流程

```
trainer = TwoStageTrainer(model_name="hfl/chinese-macbert-base")

# 阶段 1: SL 预训练
pretrained_path = trainer.stage1_supervised_learning(
    train_data=train_pairs,
    val_data=val_pairs
)

# 阶段 2: RL 微调
rl_model = trainer.stage2_reinforcement_learning(
    pretrained_model_path=pretrained_path,
    search_engine_fn=real_search_api, # 真实搜索引擎
    reward_fn=search_metric_reward
)
```

3.2 多样性排序 (Diversity Ranking)

问题背景

传统排序只关注相关性，导致Top结果高度相似：

问题：全部来自同一数据源（限额说明），覆盖度不足

方案：MMR (Maximum Marginal Relevance)

经典算法（Airbnb 论文）：

$$score(q, d_i) = \lambda * Rel(q, d_i) - (1 - \lambda) * \max_{j < i} Sim(d_i, d_j)$$

含义：

- $Rel(q, d_i)$: 与查询的相关性
- $Sim(d_i, d_j)$: 与已选文档的相似度
- λ : 平衡参数 (通常 0.7-0.8)

实际线上为了降低开销，直接基于同一数据来源的数据进行惩罚

3.3 实体识别 (NER)

技术方案：BERT + Pointer Network

模型架构：

Input → BERT Encoder → Pointer Network → (Start, End) 位置

相比传统 BIO 标注的优势：

- 直接预测实体的起止位置
- 避免误差累积（B-I-O 标签链式依赖）
- 支持嵌套实体

数据格式：

```
{
  "text": "谁是银行人事负责人",
  "entities": [
    {"type": "ORGANIZATION", "start": 2, "end": 3, "text": "银行"},
    {"type": "DEPARTMENT", "start": 4, "end": 5, "text": "人事"},
    {"type": "POSITION", "start": 6, "end": 8, "text": "负责人"}
  ]
}
```

训练技巧：

- 使用 MacBERT 替代 BERT（M LM 预训练任务更优）
- 多任务学习：NER + 关系抽取联合训练
- 数据增强：同义词替换、回译

效果对比：

详细实现参考：[NER/NER/](#) 目录

四、积累

查询改写: NMT+RL 两阶段优化框架

多样性排序: MMR 实体识别: BERT+Pointer Network 高精度方案

索引构建: RAPTOR + Late Chunking + 知识图谱

五、优化 (2026)

第一阶段：基础能力加固（Q1-Q2）

项目	时间	目标	关键结果
搜人场景优化	3 月	提升人事搜索准确率	- Query改写纠错 - 通讯录模糊匹配
数据监控看板	3月	监控数据接入和告警看板	
Agentic 框架改造	4 月	支持 Skills 扩展	- 实现工具调用接口 - 支持 workflow编排 - 万能服务路由

预期收益：

- 人事场景 Badcase 减少 50%

第二阶段：智能化升级（Q2-Q3）

项目	时间	目标	关键结果
知识图谱构建	6 月	大模型自动抽取 KG	- 实体关系抽取准确率>85%
记忆模块	8 月	用户画像与历史上下文	- 个性化召回 - 对话状态追踪

技术亮点：

```
# DeepResearch 示例
Query: "张三是哪个部门的？他的上级是谁？"
↓
分解：
1. 查询张三的部门 → 人事部
2. 查询人事部的负责人 → 李四
3. 返回：张三属于人事部，上级是李四
```

第三阶段：技术探索（Q3-Q4）

项目	时间	目标	关键结果
Reason Rank	8 月	推理感知排序	- 7B 模型超越 32B 效果- 引入思维链验证
Tree Structure Index	8 月	层次化召回实验	- 支持父子节点联合检索 - 长尾 Query 召回率提升

创新点：

- Reason Rank: 让 Reranker 具备推理能力

Query: "预算审批流程"
传统 Reranker: 匹配关键词
Reason Rank: 推理出需要"流程图 + 审批权限 + 时间节点"

- Tree Index: 模仿人类查阅文档的方式

文档树：根节点（手册）→ 分支（章节）→ 叶子（段落）
检索：先定位章节，再精确定位段落

五、资源需求与风险

人力资源

人力变动较大，离职1内算法 1外算法，1测试

角色	人数	投入周期	主要职责
算法工程师	2-3	全年	模型训练与优化
工程开发	2	Q1-Q2	图谱构建和agentic框架开发