

搜索结果多样化排序:新进展与展望^{*}

李金忠^{1,2}, 刘伟东³, 陈盛博³

(1. 井冈山大学电子与信息工程学院, 江西 吉安 343009;

2. 同济大学嵌入式系统与服务计算教育部重点实验室, 上海 201804; 3. 河南大学人工智能与 5G 实验室, 河南 开封 475004)

摘要:传统搜索引擎仅通过关键词查询以返回相关性搜索结果的排序无法满足用户日益多样化的信息需求。为此,搜索结果多样化排序技术应运而生,它在保持查询相关性的基础上,考虑不同文档的新颖性以及用户潜在的多样化查询意图,向用户呈现内容更为丰富全面的排序结果。随着深度学习技术的快速发展与突破,生成对抗网络 GAN 和图神经网络 GNN 等深度学习模型也被广泛应用于搜索结果多样化排序领域。虽然近期涌现了较多搜索结果多样化排序的最新研究成果,但较缺乏对新近提出的搜索结果多样化排序方法等相关研究的综述性工作。基于此,针对近 5 年来搜索结果多样化排序的研究进展进行了一个较为全面的综述。首先,回顾了搜索结果多样化排序的发展现状和相关综述,并阐述了搜索结果多样化排序问题的定义;其次,对近 5 年来搜索结果多样化排序的最新方法进行了分类,并重点分析了每个类别中的代表性方法;再次,对主流和新颖的搜索结果多样化评价指标进行了阐述与分析,并总结了现有的主要搜索结果多样化数据集,同时梳理和分析了最新搜索结果多样化排序方法的性能,以及总结了当前搜索结果多样化排序技术的应用进展;最后,对搜索结果多样化排序的未来研究方向进行了展望,以期对相关研究人员研究搜索结果多样化排序提供参考,并促进这一领域的进一步发展与创新。

关键词:信息检索;搜索结果多样化;多样化排序;排序学习;深度学习

中图分类号:TP18

文献标志码:A

doi:10.3969/j.issn.1007-130X.2025.12.014

Diversified ranking of search result: Recent progress and prospects

LI Jinzhong^{1,2}, LIU Weidong³, CHEN Shengbo³

(1. College of Electronic and Information Engineering, Jinggangshan University, Ji'an 343009;

2. The Key Laboratory of Embedded System and Service Computing, Ministry of Education, Tongji University, Shanghai 201804;

3. Artificial Intelligence and 5G Laboratory, Henan University, Kaifeng 475004, China)

Abstract: Traditional search engines, which only return sorted relevant search results based on keyword queries, can no longer meet users' increasingly diverse information needs. To address this, search result diversification ranking technology has emerged. On the basis of maintaining query relevance, this technology considers the novelty of different documents and users' potential diverse query intents, presenting users with ranked results that are more comprehensive and rich in content. With the rapid development and breakthroughs of deep learning technology, deep learning models such as generative adversarial networks (GANs) and graph neural networks (GNNs) have also been widely applied in the field of search result diversification ranking. Although a large number of latest research achievements in search

^{*} 收稿日期:2024-04-26;修回日期:2024-08-08

基金项目:国家自然科学基金(62141203, 62102133);井冈山大学科研基金(JAI4S2501);同济大学嵌入式系统与服务计算教育部重点实验室开放课题(ESSCKF2024-13);电子数据管控与取证江西省重点实验室开放课题(20242BCC32027-8);江西省教育厅科技计划(GJJ2201657);江西省高层次人才紧缺海外人才计划(20232BCJ25026);吉安市指导性科技计划(20244-029651);开封市重大科技计划(21ZD011)

通信地址:343009 江西省吉安市青原区学苑路 28 号井冈山大学电子与信息工程学院。

Address: College of Electronic and Information Engineering, Jinggangshan University, 28 Xueyuan Road, Qingyuan District, Ji'an 343009, Jiangxi, P. R. China

result diversification ranking have emerged recently, there is a lack of review work on newly proposed search result diversification ranking methods and other related studies. Based on this, this paper conducts a relatively comprehensive review of the research progress in search result diversification ranking over the past 5 years. Firstly, it reviews the development status of search result diversification ranking and related reviews, and expounds on the definition of the search result diversification ranking problem. Secondly, it classifies the latest methods of search result diversification ranking in the past 5 years, and focuses on analyzing the representative methods in each category. Thirdly, it elaborates on and analyzes mainstream and novel evaluation metrics for search result diversification, summarizes the existing major datasets for search result diversification, sorts out and analyzes the performance of the latest search result diversification ranking methods, and finally summarizes the application progress of current search result diversification ranking technologies. Furthermore, it looks forward to the future research directions of search result diversification ranking, aiming to provide references for relevant researchers in their studies on search result diversification ranking and promote further development and innovation in this field.

Key words: information retrieval; search result diversification; diversified ranking; learning to rank; deep learning

1 引言

随着网络信息量激增,用户可以更加方便地访问到越来越多的网络信息和服务,网络搜索已经成为人们在互联网上查找信息的主要方式。传统的搜索系统旨在从资源集合中获取与用户发起的查询背后的信息需求相关的文档,然后经过相关性排序后将搜索结果呈现给用户。然而在真实情景下,用户发出的查询往往为短查询,容易出现歧义^[1,2],传统检索方法忽略了满足各个用户意图的重要性。例如,用户输入查询词“麒麟”进行检索时,搜索结果中只出现关于中国古代神话中瑞兽麒麟的信息,虽然返回的结果和查询词是相关的,但是这并不是最理想的,因为“麒麟”对于不同用户而言有着不一样的需求含义,比如麒麟芯片、麒麟歌曲、麒麟操作系统等。进一步而言,用户搜索“麒麟芯片”时可能也希望从检索结果中得到关于“麒麟芯片发展历程”“麒麟芯片最新型号”等多样化信息,如图1所示。

为了使搜索结果集合信息最大化以提高不同用户的信息需求和满意度与体验,搜索引擎不仅要呈现相关的排序结果,而且要以多样化的方式呈现。因此,如何实现搜索结果多样化排序是提升用户使用现代搜索引擎和推荐系统体验的一个关键问题。

搜索结果多样化排序任务研究受到学术界和工业界广泛关注,大量研究成果不断涌现。按照不同的分类标准可以将目前的搜索结果多样化排序方法分为不同的类别。1)根据是否显式地建模子




Figure 1 Diversified search results

图1 多样化搜索结果

主题,可将搜索结果多样化排序方法分为显式方法和隐式方法。显式方法是指显式地考虑用户意图的多样化排序方法,通常通过识别用户查询意图的不同方面(即子话题)来实现多样化排序。而隐式方法通常只考虑文档之间的相似性,认为一个满足多样化的搜索结果文档集中,每一个结果文档彼此之间的不相似度越高,多样化程度也就越高。2)根据如何选取多样化文档集合的方法进行分类可以划分为贪婪式方法和全局式方法。贪婪式方法(也被称为“下一个文档”范式)被广泛使用,它采用迭代选取的贪心策略,即在每一个位置上都根据当前情况在候选文档集合中挑选评分最高的文档,直到选取到足够数量的文档。贪婪式方法由于采用贪心算法,总是从局部出发,而没有从整体考虑,因此往往只能得到次优解。而全局式方法是对所有候选文档集合信息进行全盘考虑,一次性对所有文档进行评分,然后根据评分进行排序后得到最终多样化搜索结果排序列表。相比贪婪式方法,全局式方法更有可能达到全局最优解,同时其时间开销也更

有优势。

随着深度学习技术的快速发展与突破,近年来涌现了许多采用深度学习技术的方法,如生成对抗网络和图神经网络等深度学习模型,来设计搜索结果多样化排序方法的最新研究成果。但是,近5年来,关于搜索结果多样化排序的综述较少,且大多缺乏对新提出的搜索结果多样化排序方法的总结。本文将主要综述近5年来搜索结果多样化排序的最新研究进展,并展望其未来的发展方向,以期为学术界和工业界的相关研究工作者提供一定的帮助和思考。

本文其余部分的组织结构如下:第2节将列举现有的搜索结果多样化排序的相关综述;第3节将阐述搜索结果多样化排序问题的定义;第4节将对近5年来新提出的搜索结果多样化排序方法进行分类,并重点概述当前主要的搜索结果多样化排序方法;第5节将概述搜索结果多样化排序领域所使用的主流和新颖的评价指标;第6节将介绍目前搜索结果多样化排序常用数据集并梳理和对比分析最新搜索结果多样化方法的性能;第7节将概述搜索结果多样化排序在实际多样化排序场景中的应用;第8节将展望搜索结果多样化排序未来的发展方向;第9节将对全文做总结。

2 相关工作

基于以往对搜索结果多样化排序的大量研究工作,目前已有一些综述对搜索结果多样化从需求动机、发展历程、相关定义、算法模型及分类等方面总结与分析了搜索结果多样化的相关进展。

文献[3]从信息检索的历史演变出发,讨论了传统排名方法在歧义和冗余方面的局限性,这是推动搜索结果多样化排序研究的关键动机,为后续研究搜索结果多样化排序方法提供了铺垫。此外,还回顾和概述了搜索结果多样化问题的研究进展,并讨论了搜索结果多样化问题为 NP(Nondeterministic Polynomial time)难问题的复杂属性,且对现有的多样化方法和评价指标进行了介绍。文献[4]将查询类型分类为含义不明确的查询、明确但不完整的查询、地理相关的查询、多领域的查询和信息性的查询,并针对每种类型的查询使用不同的方法来产生多样化的排序结果。窦志成等人^[5]将显式多样化算法与隐式多样化算法按照生成的方式分为启发式(非监督式)与学习式(监督式)进行分类并详细介绍了2类现有算法的细节,同时深入分析了基于强化学习的搜索结果多样化模型探索以获

取全局最优排序;此外,还介绍了搜索结果多样化评价方法及展望了搜索结果多样化技术的研究方向。文献[6]系统地汇总了搜索和推荐系统的多样性研究,从搜索和推荐的角度介绍了检索系统中多样性的基础、定义、性能度量和方法,并首次提出了一个统一的分类框架,用于对搜索和推荐中的多样性指标和方法进行分类。

随着深度学习和大语言模型等技术的发展,研究搜索结果多样化排序的热度依然持续发酵,近年来涌现了大量的搜索结果多样化排序的新算法和新模型。为此,有必要对研究人员新近提出的算法和模型进行综述,以此抛砖引玉,进一步促进搜索结果多样化排序的快速发展。本文针对搜索结果多样化排序问题,从定义、方法及其分类、评价指标、常用数据集及主要方法性能、现实应用与未来展望等方面进行综述,重点总结近5年来的搜索结果多样化排序方法,并对现有方法进行分析与对比。

与现有综述文献相比,首先,本文主要分析与总结之前有关综述^[3-6]中未涉及的搜索结果多样化排序方法,特别是近5年提出的新算法或新模型;其次,本文提出了新的分类方法来总结和分析搜索结果多样化排序方法,从2个角度考虑分类,先根据是否对子主题显式地进行建模,将搜索结果多样化排序方法分为隐式方法和显式方法,在此分类基础上,再根据如何选取多样化文档集合将搜索结果多样化排序方法分为贪婪式方法和全局式方法;再次,对一些主流和新颖的评价指标进行了较为全面和深入的讨论,有助于读者对搜索结果多样化排序的效果评估有更明确的认识;然后,对现有主要的搜索结果多样化数据集进行了总结,同时梳理和对比分析了一些最新搜索结果多样化排序方法的性能;最后,本文从多个方面提出了较为丰富且全面的展望,所指出的未来研究方向具有较强的前瞻性,为研究人员提供了较为前沿的研究思路,并指明了一些值得探索的重点方向。

3 搜索结果多样化排序问题定义

搜索结果多样化排序在很多任务中都被视为一个重要问题,如 Web 搜索、推荐系统、问答系统和电商平台等。CARBONELL 等人^[7]于1998年提出最大化边际相关性 MMR(Maximum Marginal Relevance)模型,其关键在于同时将相关性和多样性进行衡量。因此,可以通过调节相关性和多样

性的权重来满足偏向“需要相关的内容”或者偏向“需要不同方面的内容”的要求。2009年, RAD-LINSKI 等人^[8]在 SIGIR 会议上针对多样性的不同内涵, 根据多样性与信息需求的关系, 将搜索结果多样化大致分为 2 类, 即外在多样化和内在多样化。外在多样化旨在解决给定查询语句的信息需求的不确定性。这类多样化的一个典型例子是当用户查询“苹果”时, 不同的用户希望这个查询呈现不同的搜索结果。但由于搜索引擎不知道用户是对水果苹果、电子产品的苹果手机或者苹果电脑抑或是这个查询的其他含义感兴趣, 若不考虑搜索结果的多样性, 将会导致所返回的搜索结果难以满足不同用户的信息需求, 从而降低用户体验。外在多样化可以进一步细分为 2 个子组: 源于用户查询语句所引用实体的模糊性的多样化和关于用户的不确定性的多样化。例如用户查询“苹果手机”时, 普通消费者可能会想要了解苹果手机的具体型号和价格、性能参数配置、用户评价反馈等信息, 而对于科技爱好者则可能想要查询苹果手机的制造工艺、硬件维修技术及其软件开发与维护技术等信息, 因此使搜索结果包含各种查询含义和满足多个用户意图的能力越强, 其外在多样化就越显著。与外在多样化将多样性视为信息需求的不确定性不同, 内在多样化将多样性视为信息需求本身的一部分, 即当给定一个具有明确意图的查询语句, 多样化可以被视为避免内容冗余的问题, 从而为明确的查询需求提供相关且多样化的搜索结果。比如已知用户搜索的“苹果”是指苹果这类水果, 那么用户更加希望可以看到关于苹果这种水果所涉及的所有信息, 包括有关描述它的文本、图像、视频和音频等信息, 而不是只能看到同一类信息, 例如只展示水果苹果的文本这类描述信息。从整体上看, 外在多样性是针对具有多种搜索意图的场景进行优化, 而内在多样性是对仅具有单一搜索意图的场景进行优化。在现实世界中, 这 2 种多样化在搜索和推荐中都很重要, 可以用分层和联合的方式来衡量。

DROSOU 等人^[9]将搜索结果多样化的定义分为 3 大类型, 即基于内容的多样化、基于新颖性的多样化和基于覆盖范围的多样化。基于内容的多样化与 MMR 方法较为相似, 要求返回的搜索结果既与查询高度相关, 同时又使文档之间的相似度尽可能最小。基于新颖性的多样化与基于内容的多样化类似, 但在考虑文档内容的基础上还考虑当前返回文档相对先前已选文档的新颖性信息量, 要求覆盖更多尚未出现的新信

息。基于覆盖范围的多样化与显式搜索结果多样性排序方法的思想一致, 旨在使返回的搜索结果排序列表尽可能覆盖用户查询意图中的多个子话题或者说子方面。

4 搜索结果多样化排序方法及分类

针对搜索结果多样化排序方法, 从不同的视域出发, 本文将按照以下方式进行分类: 1) 根据是否对子主题进行建模, 分为隐式方法和显式方法; 2) 根据选取多样化文档集合的方式, 分为贪婪式方法和全局式方法。这 2 类分类方法并不重叠, 可以组合使用。

搜索结果多样化排序问题是一个 NP 难问题, 为了实现全局最优排序, 模型必须尽可能搜索该问题的所有搜索空间来优化排序模型从而实施排序。因此, 贪婪式算法是被广泛使用的一类算法, 其算法目标为设计出一个模型 f , 为给定查询 q 当前已选定文档序列 C 挑选新颖性得分 NS 最高的文档 d , 这个过程可以表示为: $NS = f(q, d, C)$ 。这个过程迭代选择次优文档, 最终生成结果序列 R 。然而, 这种贪婪式的文档选择机制存在局限性, 它只考虑每个候选文档与所选文档序列之间的局部交互, 忽略了候选文档与其他候选文档之间的全局交互。由于计算所有候选文档的信息效用不是独立的, 因此当选择一个候选文档时, 其他文档的信息效用也会受到影响, 这可能会导致全局最优文档排序的损失, 即这种贪婪式的文档选择机制可能无法达到全局最优文档排序。

为了更有可能达到全局最优文档排序, 研究人员将强化学习应用到搜索结果多样化任务中。XIA 等人^[10]将马尔可夫决策过程 MDP (Markov Decision Process) 引入搜索结果多样化排序任务中, 提出了 MDP-DIV 模型。FENG 等人^[11]提出了基于蒙特卡罗树搜索 MCTS (Monte-Carlo Tree Search) 的 M2DIV 模型, 然而, 由于 MCTS 十分耗时, M2DIV 很难训练, 而且 M2DIV 只对文档的新颖性进行建模, 因此忽略了子主题覆盖。基于深度强化学习的多样化模型在理论上能取得全局最优解, 但存在训练时间过长的缺点。

本文介绍的全局式方法注重对候选文档集合的全局交互, 与贪婪式方法选择次优文档依次生成最终结果序列 RL 不一样, 全局式方法通过模型 f 同时计算所有候选文档 D 的排名得分 S_D , 这个过程表示为 $S_D = f(D, q)$, 最后根据文档得分对文档集合进行排序得到最终多样化文档序列 R 。

图2是对近5年来各类搜索结果多样化排序方法的汇总,并展示了各方法出现的年份。各类方法各有特点,接下来将从显式和隐式建模视角对各类方法进行划分,并在此过程中介绍全局式和贪婪式方法及与其结合的应用。




Figure 2 Summary of methods for search result diversification

图2 搜索结果多样化排序方法汇总

4.1 隐式多样化排序方法

隐式多样化排序方法是最为经典的搜索结果多样化排序方法之一,这类方法将重心放到各个文档之间的差异上,通过对每个文档之间的差异性进行判断,可以在选择与查询相关的文档的同时避免重复选择类似的文档,给用户满足多样化需求的搜索排序结果。

CARBONELL 等人^[7]于1998年提出最大边际相关性算法 MMR 来解决搜索结果多样化排序的难题。他们考虑将文档与查询的相关性以及文档信息之间的新颖性相结合来对文档集合进行排序,避免了仅考虑查询相关性排序而导致的文档冗余问题。MMR 算法通过一个参数来线性组合文档查询相关度和文档信息新颖度,其中,文档信息的新颖度与该文档和已选中文档集合有关,文档和已选中文档集合的相似度越高,则其新颖度越小,MMR 算法的形式化表达式如式(1)所示:

$$MMR = \underset{d_i \in R \setminus S}{\operatorname{argmax}} [\lambda \cdot \operatorname{Rel}(d_i, Q) - (1 - \lambda) \max_{d_j \in S} (\operatorname{Div}(d_i, d_j))] \quad (1)$$

其中, Q 为查询语句; d_i 为当前文档; R 为所有候选文档集合; S 为当前已选中文档集合; $\operatorname{Rel}(d_i, Q)$ 表

示为文档 d_i 与查询 Q 的相关性; $\operatorname{Div}(d_i, d_j)$ 为文档 d_i 与当前已选中文档集合 S 中各个文档 d_j 的新颖性; 参数 $\lambda \in [0, 1]$ 用于调整二者的权重,使最终结果序列在相关性和多样性之间取得平衡。

隐式多样化排序方法大多都是基于 MMR 算法进行改进的,早期的典型隐式多样化排序方法主要包括 R-LTR (Relational-Learning To-Rank framework)^[12]、PAMM (Perceptron Algorithm using Measures as Margins)^[13]、PAMM-NTN (PAMM-Neural Tensor Network)^[14] 等等。近年来研究人员针对隐式多样化排序方法从深度学习技术、算法逻辑等角度进行优化,表1总结了近年来主要代表性隐式多样化排序方法,并进行了对比分析,下文将分别对各种方法展开详细分析。

4.1.1 MatchingDIV 方法

VASWANI 等人^[24]提出完全基于自注意力机制的 Transformer 模型,在许多自然语言处理、信息检索任务上取得了巨大成功。自注意力机制是一种能够对序列中每个位置建模并计算序列中每个隐藏状态表示的注意力机制。相较卷积神经网络 CNN (Convolutional Neural Network) 和循环神经网络 RNN (Recurrent Neural Network),自注意力神经网络 SAN (Self-Attention Network) 能够更有效地建模长距离依赖关系,同时更适合并行化。在搜索结果多样化排序任务中,自注意力机制可以用于捕捉候选文档之间的全局交互信息,学习到候选文档之间的相似性和差异性,从而提高搜索结果的多样性。

传统的搜索结果多样化排序方法大多使用预训练的嵌入来表示候选文档,通过计算2个文档嵌入的余弦相似度等方式来评估文档的相似程度,但这些方法会丢失文档之间细粒度的匹配信号。QIN 等人^[15]提出的 MatchingDIV 方法采用基于交互的神经匹配信号来实现隐式搜索结果的多样化排序。该方法使用自注意力模块交叉关注,来捕捉文档与查询之间的细粒度匹配信息,并让已选文档序列中的每个文档与候选文档进行交互。通过捕获和聚合每个候选文档与已选文档序列之间的细粒度匹配信息,更准确地计算文档相似度,提高隐式搜索结果多样化排序的性能。自注意力分数的计算公式如式(2)所示:

$$\operatorname{Attn}(\mathbf{q}, \mathbf{k}, \mathbf{v}) = \operatorname{Softmax}\left(\frac{\mathbf{q}\mathbf{k}^T}{\sqrt{d}}\right)\mathbf{v} \quad (2)$$

其中, $\mathbf{q}, \mathbf{k}, \mathbf{v}$ 分别表示为查询矩阵(query matrix)、

Table 1 Comparison of major implicit diversification ranking methods

表 1 主要隐式多样化排序方法对比

方法	选取方式	主要结构	优点(主要工作)	缺点
MatchingDIV ^[15]	贪婪式	多头注意力神经网络、循环神经网络	使用多头注意力机制捕捉文档间细粒度匹配信息,选取新颖性文档	方法复杂度高,计算资源需求量大
Query-Transformer ^[16]	全局式	多头注意力神经网络	当候选文档序列经过相关性排序后输入时,能充分利用候选文档初始序列有效信息	需按照某种先验知识对候选文档集合排序,在不存在先验知识的情况下性能较差
DALETOR ^[17]	全局式	多头注意力神经网络	通过使用 Sigmoid 函数平滑逼近子主题覆盖次数与当前位置,将评价指标对接于模型损失函数中,可直接针对独特的评价指标进行优化	模型训练需要预定义较多的全局调优参数,训练难度较高
MO4SRD ^[18]	全局式	多头注意力神经网络	使用了概率打分和高斯分布建模,使用概率来代替评价指标中的指示函数,将评价指标改良为连续的损失函数	模型直接使用某个评价指标作为优化目标,可能导致模型过度拟合特定的评价指标,而忽视了其他可能同样重要的指标
Graph4DIV ^[19]	贪婪式	图卷积神经网络	首次使用图结构建模文档及查询间的关系,可更好捕捉文档、查询之间的关系	需要额外的模型来构建图,存在多个模型误差累积问题
GAT-DIV ^[20]	贪婪式	图注意力神经网络	使用图注意力神经网络建模,具备 Graph4DIV 中图结构的优势,且不需要预先构建图的结构,可避免误差累积问题	多样性特征提取器的设计较为简单,无法充分表达文档
KEDIV ^[21]	贪婪式	基于知识图谱的图神经网络	具备 Graph4DIV 的优势,同时使用知识图谱以帮助构建图神经网络,可解释性强	需要依赖良好的知识图谱来帮助构建图神经网络
PAD ^[22]	贪婪式	多头注意力神经网络	引入了段落感知的文档与子主题交互,多种细粒度的交互帮助模型更准确地测量文档的子主题覆盖率	需要高质量的分类器模型,多阶段的训练增加了模型的训练复杂度和时间成本。
CL4DIV ^[23]	全局式	多头注意力神经网络	有效利用无标签数据,缓解数据稀缺问题,提高文档和文档序列的表示质量与鲁棒性	使用非人工标注子主题,与真实用户意图可能存在差异

键矩阵 (key matrix) 和值矩阵 (value matrix); d 表示缩放参数,大小与 k 的列数相等。需要注意的是自注意力模块中涉及的查询矩阵与信息检索中的查询语句在名字上相同,但在含义上有所不同。Transformer 中的查询矩阵“query”是表示输入文档的张量,用于计算文档与查询之间的相似度,而信息检索中的“query”是用户输入的查询语句。

多头注意力用于不同策略学习不同文档多个方面的特征,其计算方式如式(3)和式(4)所示:

$$a_i = \text{Attn}(qW_i^q, kW_i^k, vW_i^v), i \in \{1, 2, \dots, h\} \quad (3)$$

$$\text{MultiHead}(q, k, v) = [a_1; \dots; a_h] \quad (4)$$

其中, i 表示当前自注意力头的序号; a_i 表示第 i 个头的自注意力分数; W_i^q, W_i^k, W_i^v 分别表示 q, k, v 的对应可学习权重矩阵,在训练过程中通过梯度下降等算法进行优化; $\text{MultiHead}(\cdot)$ 表示多头注意力模块的总输出。

Transformer 的所有参数矩阵都是学习到的参数,它们的值在训练过程中通过梯度下降等算法进行优化。

MatchingDIV 方法使用 BERT (Bidirectional Encoder Representations from Transformers)^[25] 获得文档的潜在空间表示 E , 接着将每个候选文档 d 和所有已选文档 d_i 使用基于 Transformer 的多

头注意力机制进行术语级别的交互以得到在已选文档术语级别上增强的表示 I_{d_i} , 其计算方式如式(5)所示:

$$I_{d_i} = \text{MHA}(E_{d_i}, E_d, E_d) \quad (5)$$

在获得已选文档术语级别上的增强表示 I_{d_i} 后,使用 RNN 递归地聚合每个文档内的交互特征,最终形成文档的匹配向量。最后,再次通过 RNN 聚合列表中各文档的匹配向量,获得列表整体与候选文档的匹配程度向量。

通过上述分层交互和递归聚合,整合了文本的语义匹配与已选文档列表的新颖性建模。细粒度交互的方式,使得文档关系的刻画更加精细,从而提升了搜索结果多样化的质量。

4.1.2 Query-Transformer 方法

近年来序列模型发展迅速,以 RNN 与 Transformer 为代表的注意力机制模型在排序学习领域得到广泛应用。在相关性排序任务中,最早探索的工作是基于 Transformer 的序列模型^[26]。由于这些模型能更好地捕捉文档之间的相互关系,它们表现出较强的排序能力。QIN 等人^[27]首先提出了基于自注意力神经网络 SAN 的搜索结果多样化显式方法 DESA (Diversity Encoder with Self-Attention), 关于 DESA 方法详细原理,将在 4.2.2 节中进行描述。

然而基于自注意力神经网络 SAN 的模型大

多依赖于 Transformer 中的编码器,相关研究^[28]表明基于 SAN 的模型具有置换不变性,即改变输入的文档序列位置不会影响最终的输出。在搜索结果多样化排序任务中,查询对应的候选文档集合一般是基于相关性对文档进行排序的。而由于当前学术界可获得的标注训练数据集较少,SAN 无法充分利用数据集中候选文档初始排序所带来的先验查询相关性特征。

受到 Star-Transformer^[28] 的启发,秦绪博等人^[16]提出了一种基于双星型 SAN 结构的搜索结果多样化方法 Query-Transformer。在该方法中,双星型注意力机制如图 3 所示,该图展示了一个长度为 4 的文档序列,其中圆形为文档卫星节点,三角形为查询节点,正方形为中继节点,各节点对应其向量表示。与传统自注意力机制的节点全连接结构不同,双星型自注意力机制中每个文档节点之间进行首尾相连,此外,每个文档节点仅与查询节点、中继节点、与自己直接相邻的节点进行连接。查询节点通过与文档进行连接的方式来提取文档与查询的交互特征信息,中继节点的作用在于让不相邻的节点之间也可以进行交互。所有文档节点与查询节点形成一个星型网络结构,与中继节点形成另外一个星型网络结构,从而构建完整的双星型自注意力机制网络。




Figure 3 Dual star-shaped self-attention network

图 3 双星型注意力机制

通过改变传统 SAN 基于全连接的结构,双星型网络结构显式地衡量文档卫星节点彼此间的顺序,并且使用经过预训练的位置编码来显式地衡量输入文档序列的位置信息,高效利用多样化排序任务中输入经过相关性排序后的文档初始序列带来的先验的文档相关性特征信号,从而更高效地捕捉文档与查询的相关信息。

但需要注意的是,虽然使用基于双星型自注意力网络的搜索结果多样化方法在输入符合条件的文档序列情况下,搜索结果多样化序列会覆盖更多与查询相关的文档,但是已有实验也证明了当输入为没有经过相关性排序的文档初始序

列时,所提方法的性能会降低,因此在实际使用中需要考虑使用场景是否与方法适配。

4.1.3 基于损失函数对接评价指标优化的 DALETOR 和 MO4SRD 方法

YAN 等人^[17]提出 DALETOR 模型,他们发现以往的搜索结果多样化研究工作通常属于“下一个文档”范式,即在基于学习的方法中,依次选取单个文档,也被称作贪婪式方法。这样的方法需要考虑指数级别的排序列表,使得学习的难度增加。因此,他们提出了一个软版本的“下一个文档”范式,为每个文档估计一个近似的排名,通过这种方式估计某文档之前的子话题覆盖情况。具体来说,他们假定为每个文档设定一个得分,基于这个得分使用 Sigmoid 函数来平滑地逼近文档的排名和子话题覆盖数。这种做法可以跳过逐步筛选的过程,直接根据这个得分对文档进行排序。通过这种方法避免了传统的“下一个文档”范式中的组合爆炸问题,可以高效地进行端到端学习,推理时也更加简单高效,只需要根据得分进行排序,而不需要逐步计算排列组合。

DALETOR 使用基于 BERT 等预训练语言模型获得查询和文档的潜在空间向量表示。潜在空间向量表示可以让神经网络学习潜在空间中子主题的特征,同时子主题和候选文档之间的匹配也可以在训练过程中进行学习。此外,评分函数使得对涵盖相同子主题分布的文档可以在和查询与子主题独立的维度中学习,避免了 2 个子主题覆盖范围一致的不同文档得到同一个分数。其算法流程是:首先,将查询和文档表示进行交互,获得文档和查询的交互特征;其次,将所有文档表示传入自注意力层,获得每个文档的上下文特征向量,并以其作为补充特征来区分覆盖相同子主题范围的文档;再次,将查询、文档、交互特征、上下文特征向量拼接,并输入全连接层以获得每个文档的多样性得分;最后,将多样性得分输入到可微分的多样性损失函数中进行反向传播训练。重复上述过程,通过端到端学习调整模型参数,使模型学习到能够进行多样化排序的打分函数。

搜索结果多样化排序工作采用常用的评价指标如 α -nDCG^[29]、ERR-IA^[30] 来评估当前模型的性能,而这些指标都涉及到文档当前的排名以及当前已选文档涉及某个子主题的数量,这些信息在数值上都是整数且具有不可导的性质,如传统的评价指标函数中通常会包含指示函数 I 。指示函数 I 负责统计当前文档 d_i 和已选文档集合 S 中所有文

档的某种关系来计算评价指标,如 k_i 为当前文档 d_i 的排名位置,其中需要指示函数 I 帮助统计当前文档得分低于其他文档得分的数量,而 c_{it} 为所选文档集合和子主题的覆盖次数,同样需要指示函数 I 来帮助计算,它们的计算方式分别如式(6)和式(7)所示:

$$k_i = 1 + \sum_{d_j \in S, j \neq i} I_{s_j > s_i} \quad (6)$$

$$c_{it} = \sum_{d_j \in S, j \neq i} y_{jt} I_{s_j > s_i} \quad (7)$$

其中, s_i 和 s_j 分别表示文档 d_i 和 d_j 的得分; y_{jt} 表示文档 d_j 是否覆盖子主题 t ,对于二元标签分类,如果 $y_{jt} = 1$ 则表示文档 d_j 覆盖子主题 t ;反之,如果 $y_{jt} = 0$ 则表示没有覆盖子主题 t 。

由于指示函数是离散的,因此在以往研究工作的损失函数中通常不会和多样性评价指标有关联,而是使用交叉熵损失函数等来进行反向传播。DALETOR 使用 Sigmoid 函数来平滑地逼近文档的排名和子话题覆盖数,可以获得文档排名和子话题覆盖的可导表达式,进一步可以得到可微分的多样性评价指标损失函数,实现了评价指标和损失函数相关联的目的,可以更好地针对某些评价指标进行优化。具体来说,文档 d_i 的排名位置 k_i 与其子主题 t 的覆盖次数 c_{it} 分别采用式(8)与式(9)的计算方式来获得:

$$k_i = 1 + \sum_{j \neq i} \text{Sigmoid}\left(\frac{s_j - s_i}{T}\right) = \frac{1}{2} + \sum_j \left[1 + \exp\left(\frac{s_i - s_j}{T}\right)\right]^{-1} \quad (8)$$

$$c_{it} = \sum_{j \neq i} y_{jt} \cdot \text{Sigmoid}\left(\frac{s_j - s_i}{T}\right) = \sum_j \frac{y_{jt}}{1 + \exp\left(\frac{s_i - s_j}{T}\right)} - \frac{y_{it}}{2} \quad (9)$$

其中, T 为 Sigmoid 函数的温度系数。

YU^[18] 认同 YAN 等人^[17] 此前通过优化损失函数的工作证明这一思路的可行性,但他们认为 DALETOR 获取每一个文档的近似排名时需要全局调优参数(参数、评分函数、网络结构的不确定性是需要的),这会影响最终性能。因此他提出 MO4SRD 模型^[18],其改进思路是使用一个基于概率分布的多样性得分来确定其排名位置。在评分函数上选择使用一个单一变量分数来表示,其次将这个分数值看作是一个服从高斯分布的概率值。一个文档的多样性高于另一个文档则表征为前一个文档的分数值大于后者的。由于该分数服从高

斯分布,因此 2 个文档之间的分值差也服从高斯分布。使用概率的方式来代替原有的指示函数,解决了上文提到的指示函数不连续的问题,从而将评价指标改良为连续的损失函数。

4.1.4 基于图神经网络的 Graph4DIV 与 GAT-DIV 方法

图神经网络作为一种可以对图结构数据进行建模的有效工具,在信息检索领域被广泛应用。相比传统的向量空间模型,图网络可以更自然地表示用户与物品间的复杂交互关系。图卷积网络 GCN (Graph Convolutional Network) 通过将传统的卷积运算从固定度的节点推广到可扩展度的节点来收集邻居的信息,经过图卷积运算后图上的节点表示会通过其相邻节点得到增强。由于隐式搜索结果多样化排序方法基于文档之间的不相似性来建模文档的新颖性, SU 等人^[19] 提出基于 GCN 的 Graph4DIV 方法,他们认为传统使用文档内容之间的不相似性来间接模拟多样性是不自然的,为了更精确地处理多样性,通过选择使用意图覆盖性来度量文档之间的相似性。

图 4 为 Graph4DIV 方法中意图图的构造与更新流程,首先使用 BERT 来提取文档的潜在空间表示,将候选文档集合中的文档两两匹配,通过构建基于潜在空间表示的关系分类器对文档之间的意图是否相似进行判别,如果相似,则在图中将它们连接起来,并基于此构造一个意图图来表示文档和查询之间的复杂关系。Graph4DIV 方法使用贪婪式方法依次选择多样性得分最高的文档,而每次文档选择结果是将查询与已选文档进行连接,同时断开其与候选文档集合的边,最后使用 GCN 通过聚合其邻居来更新查询的表示和每个文档的表示。在 Graph4DIV 方法中,可以在文档选择过程中通过动态调整意图图来获得具有上下文感知的查询表示和具有意图感知的文档潜在空间表示。此外,将意图图特征融合到多样性特征中,作为最终文档多样性评分函数的一个重要组成部分。




Figure 4 Construction and update of intent graph of Graph4DIV

图 4 Graph4DIV 意图图的构造与更新

Graph4DIV 方法通过使用 GCN 构建图的方式来获取文档之间复杂关系的方法虽然有效,但需要额外模型来进行分类以辅助构建图,因此可能会带来误差累积的问题。XU 等人^[20]提出 GAT-DIV 方法,通过使用图注意力网络而不是图卷积网络来建模查询和文档之间的关系。图注意力网络的一个显著优点是不需要预先构建图的结构,而是通过引入注意力机制,使每个节点可以根据其邻居的特征向量进行自适应加权,因此不需要事先确定全局的连接结构,从而可以更加灵活地处理不同类型的图。

4.1.5 KEDIV 方法

用户输入的查询语句往往是模糊的,基于文本内容的相似度来构建多样性的方法难以学习到其中的一些潜在关联。由于实体经常出现在文档中,而知识库中实体的关系是明确的、有意义的,因此利用实体和它们之间的关系来弥补查询和文档之间的差距是对搜索结果多样化排序任务有帮助的:首先,实体所包含的明确含义可以帮助消除歧义和推断出文档所包含的主题;其次,知识库带来的丰富信息和良好的组织关系可以反映出文档的潜在关系,这一点仅从文本中难以学到。

SU 等人^[21]提出了 KEDIV(Knowledge Enhanced search result DIversification)方法,该方法利用知识库中的实体和关系来增强搜索结果的多样化,通过构建查询特定的关系图的方法,使用 Freebase 知识库^[31]提取了 4 种实体关系,分别是实体-词语共现关系、实体类别关系、知识库原有关系和文档-实体关系。其中,实体-词语共现关系是对文档的词序列进行分析获得的,如果查询词与文档中的实体出现在一定距离内,则在关系图中连接查询词节点和实体节点;实体类别关系是直接从知识库的实体属性中获得的,如果 2 个实体属于同一类别,则在关系图中连接这 2 个实体节点;知识库原有关系是从知识库中获取的,如果 2 个实体在知识库中原本存在关系,则在关系图中连接这 2 个实体节点;文档-实体关系则是通过命名实体识别和链接获得文档中的实体,如果实体出现在文档中,则添加实体节点到文档节点的有向边。

将查询、文档和实体之间的 4 种关系建模,全面表达它们之间的关联,然后从关系图中提取实体和文档表示作为文档的多样性特征,最后结合相关性特征生成最终的排序分数。KEDIV 属于贪婪式方法,其思想是随着候选文档不断被选择,已选文档集合中的信息也应当被考虑。该方法使用 GCN 等

网络,通过考虑当前已选中文档中包含的实体、文档信息来更新关系图中节点的表示及其节点权重,最后将图中的信息作为多样性特征结合其他相关性特征输入多层感知机中得到该文档的得分。

通过知识图谱的 4 种关系能全面地连接查询、文档和实体,并充分利用知识库的丰富信息,有助于模型理解文档之间的关系,从而实现搜索结果多样化。KEDIV 方法具有较高的可解释性并且能取得不错的排序效果,但比较依赖知识库的质量,同时其关系图的计算比较复杂,也没有考虑查询的层次信息。

4.1.6 PAD 方法

SU 等人^[22]认为以前的研究将文档视为一个整体,并且用单一长度的向量进行表示,但考虑到一个长文档可能涵盖查询的不同方面,单个向量表示往往不足以充分反映文档内容。为了解决这一问题,他们提出了一种基于段落感知的搜索结果多样化排序方法 PAD(Passage-Aware Diversification)。PAD 的核心在于利用文档内部不同段落的信息来进行搜索结果的多样化,通过段落级别的文档建模和细粒度的文档—子主题交互,显著提升了搜索结果的多样性和相关性。

具体来说:首先,PAD 使用滑动窗口技术将文档分割成多个固定长度的段落,并通过训练一个基于 BERT 的段落相关性分类器来筛选与查询无关的段落,仅保留相关段落以提高效率和准确性。其次,PAD 利用上下文感知的段落交互框架来加强段落和文档的表示,其中包括全局段落编码器 GloEnc(Global passage Encoder)、已选文档编码器 SelEnc(Selected documents Encoder)和候选文档编码器 DocEnc(candidate Documents Encoder)。

GloEnc 用于对整个文档进行初步编码,通过自注意力机制获取每个段落在整个文档中的全局表示,具体实现可以采用预训练语言模型,如 BERT 或 Transformer。如文档 d_i 包含 n 个段落 $\{P_1, P_2, \dots, P_n\}$,则每个段落 P_i 经过 GloEnc 编码后可以表示为式(10)所示:

$$\mathbf{h}_i = \text{GloEnc}(P_i) \quad (10)$$

SelEnc 通过组合查询表示 $\mathbf{X}_q$ 和当前所有已选文档的段落表示 $\mathbf{X}_{dp}$ 得到 $\mathbf{X}_{sp}$,以反映当前满足的查询意图状态。SelEnc 的实现和 GloEnc 类似,由多个使用注意力机制的交互层组合,最终查询表示 $\mathbf{X}_q$ 被更新为 $\mathbf{X}_s$,并作为最终的多样性特征之一,如式(11)所示:

$$\mathbf{X}_s = \text{SelEnc}(\mathbf{X}_{sp}) \quad (11)$$

更新后的查询表示 $\mathbf{X}_s$ 将与各个文档段落表示 $\mathbf{P}_{ic}$ 进行交互得到 $\mathbf{Y}_{ic}$, 使得各个文档段落表示包含上下文信息。 $\mathbf{Y}_{ic}$ 的计算方式如式(12)所示:

$$\mathbf{Y}_{ic} = \mathbf{X}_s \cdot \mathbf{P}_{ic} \quad (12)$$

其中, $\cdot$ 表示 2 个向量的点积运算, c 表示文档段落的序号。

DocEnc 通过自注意力机制聚合候选文档 d_i 经过滑动窗口段落分割、并通过段落相关性分类器筛选后得到的 k 个相关段落的上下文表示 $\mathbf{Y}_i = [\mathbf{Y}_{i0}, \mathbf{Y}_{i1}, \dots, \mathbf{Y}_{ik}]$, 得到候选文档 d_i 文档级别的多样性特征 $\mathbf{Z}_i$, 从而避免其中可能存在的冗余段落信息影响, 聚焦于新颖段落的信息, 其计算方式如式(13)所示:

$$\mathbf{Z}_i = \text{DocEnc}(\mathbf{Y}_i) \quad (13)$$

最终, 结合文档初始表示、各个多样性特征和包括 BM25、TF-IDF 等相关性特征, 通过一个多层感知器生成文档的最终排名分数。PAD 引入了段落感知的文档—子主题交互, 通过细粒度的交互来更准确地测量文档的子主题覆盖率, 有效提升了搜索结果的多样性和相关性, 但段落分类器的性能对最终的多样化效果有较大影响, 需要高质量的分类器模型, 多阶段的训练增加了模型的训练复杂度和时间成本。

4.1.7 CL4DIV 方法

大部分的搜索结果多样化方法使用预训练的文档嵌入(如 doc2vec 和 Glove)来表示文档, 但这些表示可能无法充分捕捉文档内容的细节, 也难以准确反映用户查询意图的覆盖。此外, 有限的标注数据进一步增加了获取有效文档表示的难度。为了解决这些问题, DENG 等人^[23]提出了一种基于对比学习的搜索结果多样化方法 CL4DIV (Contrastive Learning framework for search result Diversification)。

CL4DIV 方法通过设计 3 种对比学习任务来预训练文档编码器和文档序列编码器, 这些任务分别从子主题、文档和候选文档序列的角度出发, 对应搜索结果多样化中的 3 个基本要素。

1) 子主题对比学习利用 T5 模型自动生成每个文档的子主题, 避免了额外的标注成本。通过比较文档对子主题的覆盖相似性, 模拟显式多样化模型的一般过程。

2) 文档对比学习采用数据增强策略, 如随机段落删除、随机段落交换和 dropout 策略, 来模拟文档内容的潜在变化。这些策略有助于模型减少对

完整文档信息的依赖, 以学习到更鲁棒的文档表示。

3) 序列对比学习设计了基于序列的对比学习任务, 通过文档替换和文档重排序操作来生成增强的文档序列对。通过比较相似与不相似的文档序列, 模型可以识别对搜索结果多样化至关重要的信息。

对比学习损失函数的目标是 minimized 正样本对之间的距离, 同时最大化负样本对之间的距离。以基于文档的对比学习任务的损失函数为例, 其损失函数的计算方式如式(14)所示:

$$L = -\ln[\exp(\text{sim}(\mathbf{e}, \mathbf{e}')/\tau)] / [\exp(\text{sim}(\mathbf{e}, \mathbf{e}')/\tau) + \sum_{\mathbf{e}^k \in N} \exp(\text{sim}(\mathbf{e}, \mathbf{e}^k)/\tau)] \quad (14)$$

其中, $\mathbf{e}$ 和 $\mathbf{e}'$ 是原始文档和其增强版本的表示; $\text{sim}(\cdot)$ 函数用来对比 2 个文档表示之间的相似度, 可以使用余弦相似度等函数来计算; N 是负样本集合; $\mathbf{e}^k$ 是负样本的表示; τ 为温度超参数。同理, 对于子主题和候选文档序列的对比学习损失函数, 其计算方法只需分别将式(14)中的文档表示 $\mathbf{e}$ 和 $\mathbf{e}'$ 替换为子主题表示 $\mathbf{s}$ 和 $\mathbf{s}'$ 或者候选文档序列表示 $\mathbf{l}$ 和 $\mathbf{l}'$ 。

CL4DIV 方法通过对比学习任务能够从不同角度优化数据表示, 提高文档和文档序列的表示质量; 同时还能够有效利用无标签数据, 缓解数据稀缺问题, 显著提高了搜索结果的多样性和相关性。该方法为搜索结果多样化排序领域提供了新的视角和解决方案, 但引入多个对比学习任务和多阶段预训练过程, 增加了训练的复杂度和时间成本。此外, 使用生成的子主题与人工标注的用户意图之间存在一定差距, 一定程度上影响了文档相似度计算的准确性。

4.2 显式多样化排序方法

与隐式多样化排序方法关注的重点不一样, 显式多样化排序方法从用户输入的查询出发, 对底层用户查询意图进行建模, 不同用户的意图表示为查询的子主题。显式多样化排序方法更倾向于在候选文档集合中选取文档时, 尽可能多地考虑给定查询当前未被所选文档覆盖的新子主题, 使得最终返回的搜索结果序列中能够覆盖查询较多的子主题, 从而满足各类用户不同的搜索意图。

对于用户给定的查询, 首先需要了解该查询有多少相关的子主题, 以及确定每个子主题的相对重要性, 在此基础上使用结果多样化组件进行文档的重排。但此类方法依赖于子主题信息获取准确度。在传统研究中, 采用手动或从商业化的 Web 搜索

引擎如谷歌得到一些线索的方法,或采用自动的方法,如 RADLINSKI 等人^[32]提出了一种通过分析查询日志而对查询进行聚类的方法,DANG 等人^[33]则利用锚文本和 Web 文档对查询进行聚类。除了使用传统方法外,MacAVANEY 等人^[34]通过使用分布式因果语言建模 DCLM(Distributional Causal Language Modeling)提升了查询主题的质量。

相比于隐式多样化方法,显式技术更为复杂,但也有着更高的性能上限。值得注意的是,显式方法和隐式方法并非完全对立,二者可以结合使用,也被称为显隐式集成方法。通常情况下,显隐式集成方法也统一归类为显式方法。

表 2 为近 5 年来主要的代表性显式多样性排序方法的总结与对比,下文将分别对它们进行详细介绍。

4.2.1 DVGAN 方法

由 GOODFELLOW 等人^[40]提出的生成对抗网络 GAN(Generative Adversarial Networks)是一种强大的深度学习架构,主要应用于计算机视觉、自然语言处理和推荐与搜索等领域中。GAN 中生成器和判别器通过对抗训练的方式不断优化,最终生成逼真的数据样本。IRGAN(Information Retrieval GAN)^[41]首次将生成对抗网络引入信息检索领域,通过 GAN 的思想将生成检索模型和判别检索模型统一起来。基于此,LIU 等人^[35]首次将 GAN 引入到搜索结果多样化排序任务中,提出了 DVGAN(search result DiVersification using Generative Adversarial Network)方法。该方法包含采样器、生成器和判别器 3 个组件,其中,采样器

为生成器采集高质量数据,生成器试图在给定当前的查询语句 Q 和已经选中的文档集合 S 条件下生成高质量的文档,判别器负责区分正样本(真实样本)和生成器生成的负样本。在 DVGAN 方法中,生成器和判别器分别采用了显式方法 DSSA(Document Sequence with Subtopic Attention)模型^[42]和隐式方法 R-LTR 模型^[12]以融合显式特征和隐式特征,从而改善多样化质量,最终达到提高多样化的效果。值得注意的是,DVGAN 中生成器和判别器可以使用不同类别的模型,因此可以采用将显式方法和隐式方法融合的方式。

DVGAN 为神经网络模型的优化提供了 2 种不同的训练方法:DVGAN-doc 和 DVGAN-rank。DVGAN-doc 是 IRGAN 的自然扩展,生成器根据查询和已选文档给出负样本集;其训练目标是生成器试图拟合真实文档分布,使判别器无法区分生成的负样本和正样本,判别器试图区分正负样本,给生成器提供反馈。DVGAN-rank 结合了 PAMM^[13]损失函数和 GAN^[40]的思路,生成器根据查询和候选文档集合给出完整的负样本排序序列;生成器和判别器的得分函数都是基于 Plackett-Luce 模型来计算整个排序的得分,其训练目标是最大化正负样本排序序列的评价指标如 α -nDCG 的间隔。

在 DVGAN 中,对 GAN 网络进行训练时,高质量训练样本的选择是十分关键的。由于样本的总体数量是指数级别的,因此需要采样算法来减少样本空间。为此,DVGAN 中提出 2 种采样方法:理想采样和随机采样。理想采样方法通过查询各自的理想排序来截取一定数量文档作为已选择文档集合,其余文档作为候选文档集合提供给生成

Table 2 Comparison of major explicit diversification ranking methods

表 2 主要显式多样化排序方法对比

方法	选取方式	主要结构	优点(主要工作)	缺点
DVGAN ^[35]	贪婪式	生成对抗网络	结合显式与隐式方法特征建模,具有更丰富的多样性特征	生成对抗网络训练过程不稳定和易于模式崩溃,训练难度较大
DESA ^[27]	全局式	注意力神经网络	使用全局式方法选取搜索结果列表,避免陷入局部最优解	没有考虑贪婪式方法的求解局部最优解的优势
GDESA ^[36]	贪婪式	多头注意力神经网络、循环神经网络	在使用贪婪式方法过程中融合全局式特征,解决 DESA 中全局方法没有考虑当前文档选择情况的缺陷	贪婪式方法选择特征仅考虑了已选文档信息,没有考虑当前子主题覆盖的信息
DUB-SRD ^[37]	全局式	多头注意力神经网络	从文档内部出发,引入了广义可微 k -means (GDKM)方法进行子主题提取,可解释性高	模型包含多个可学习组件和超参数,参数调优过程可能比较复杂,GDKM 的计算复杂度较高
HGDIV ^[38]	全局式	基于超图结构的图神经网络	使用超图结构准确地描述文档中存在多元关联的对象之间的关系,通过全局和局部子主题分布建模有助于更准确地评估文档的多样性	模型中涉及多个超参数,训练难度较大,同时依赖所使用的聚类算法构建超图,聚类算法的性能和选择可能会影响最终的多样性效果
HAD ^[39]	全局式	多头注意力神经网络	引入层次注意力框架,通过多细粒度文档建模文档子主题多样性	文档实体提取工具的性能影响模型最终性能

器选取。随机采样方法则是随机选取一定数量文档组成已选择文档集合,其余文档则组成候选文档集合。采样方式的不同直接影响采样生成的样本数据,从而影响模型训练的效果。通常,采用理想采样和随机采样的混合采样方式,有助于提升模型效果。目前的采样方法仍然是基于启发式设计的,未来可能会出现更有效的采样方法来进一步优化模型。

4.2.2 DESA 和 GDESA 方法

以往的搜索结果多样化排序工作大多是基于贪婪式选择的方法,即每次选取一个文档的方式,但是这种方式只能得到一个局部的最优解。针对这个问题,QIN 等人^[27]首次提出了基于全局建模的具有自注意力的多样性编码器 DESA(Diversity Encoder with Self-Attention)方法。DESA 对所有候选文档的新颖性和子话题覆盖进行估计,力求通过所有候选文档的相互作用达到全局交互的效果,而不是通过贪婪式逐个选择文档以取得局部最优排名,因此更有可能获得全局最优排名。DESA 方法将各个文档以及各个查询的子主题分布式表示输入到自注意力编码器中以分别得到它们的自注意力分布式表示;接着将它们输入到文档解码器中,得到经过文档和子主题信息交互的文档解码分布式表示。使用文档和各个子主题的相关性特征经过多层感知机来得到文档和子主题的相关性得分。最后将文档编码器潜在空间表示、文档解码器潜在空间表示、文档和查询的相关性特征、文档和各个子主题的相关性得分等多种特征输入到多层感知机中,以得到这个文档的最终得分,再按照该得分对文档进行降序排序后得到最终的多样性排序。

通过 DESA 这种全局性的方法可以一次性为所有候选文档打分,从理论角度上更有可能达到全局最优解,相比贪婪式方法,可以大大减少模型的运行时间。但是传统贪婪式方法可以根据当前已选文档的情况来选择下一个文档,故这些可以避免选择那些已经覆盖了多次子主题的方法也存在其独特优势。基于此,QIN 等人^[36]将全局式方法的特点融入到贪婪式选择方法中,提出了 GDESA(Global DESA)方法以改进 DESA 方法的性能。GDESA 方法在选择文档时保留使用注意力机制来对候选文档进行全局交互的方式,以更好地表达文档的多样性。同时,在每一轮选择过程中,将当前已选择的文档集合以及候选文档输入到 RNN 模块中进行处理,通过基于 RNN 的文档选

择组件,可以模拟贪心选择过程,提供顺序交互特征。GDESA 模型在贪婪式选取方法的基础上加入了全局式方法的思想,在每轮文档选取时令不同文档进行交互,通过对候选文档间的全局交互特征以及对当前已选文档集合的局部信息进行特征提取,提高了搜索结果序列多样化的质量。

4.2.3 DUB-SRD 方法

鉴于 TISHBY 等人^[43]提出的信息瓶颈理论深刻阐释了信息提取时的准确性与简洁性之间的权衡取舍,YU 等人^[37]提出了一种端到端的面向核心信息提取的搜索结果多样化方法 DUB-SRD(Diversification Using Bottlenecks-Search Result Diversification),该方法可以同时优化文本编码器、查询子主题提取器和多样化文档排名器,以实现搜索结果的多样化排序。

DUB-SRD 通过将文档表示映射到一组互相区分的主题上,形成信息瓶颈,通过控制瓶颈宽度,实现各主题覆盖面与单个主题聚焦度之间的平衡。为了从候选文档中提取与查询相关的子主题信息以优化后续的多样化处理,DUB-SRD 采取如图 4 所示的子主题提取方式。首先,采用 BERT 对文档信息进行编码,但由于文档的长度往往超过编码器的输入限制长度,需要编码器按照一定长度将文档切分为多个小段。然后,通过子主题提取器从相关段落中挖掘查询的子主题。由于文档中可能存在多个与查询相关的段落,且可能只有部分段落与查询直接相关,因此可以通过计算各段落与查询之间的余弦相似度并设置阈值的方式滤除无关段落。




Figure 5 Subtopic extraction method of DUB-SRD

图 5 DUB-SRD 的子主题提取方式

在 DUB-SRD 方法中,设计了基于多头注意力机制 MHA(Multi-Head Attention)与广义可微 k -means GDKM (Generalized Differentiable k -means)聚类方法 2 种子主题提取器。MHA 子主题提取器将查询与文档各个段落的信息使用多头注意力进行交互。多头注意力的计算公式与 4.1.1 节中介绍的一致,但最后并不会将多个头的输出进行合并,而是将每个头的输出各作为一个子主题信

息分别保存。MHA 子主题提取器参数量较少,因此无需预训练就可以取得良好效果。GDKM 子主题提取器的性能更加优秀,图 6 为其工作流程,它采用聚类算法思想,通过段落之间的相似度进行子主题聚类,通过设置自由度的方式限制每个段落从属于子主题类别的数量,并不断迭代得到不同子主题类及其聚类中心。最后,通过使用编码器聚合每个子主题类别中的段落信息得到最终的子主题表示。

使用段落表示作为文档信息与查询子主题进行交互的方式可以舍弃许多无关信息,更有助于文档与查询的匹配。相比依赖外部系统提供的查询建议,DUB-SRD 采用上述方法从候选文档内提取子主题的方式为搜索结果多样化显式端到端模型的实现提供了新思路。




Figure 6 Workflow of GDKM subtopic extractor

图 6 GDKM 子主题提取器的工作流程

4.2.4 HGDIV 方法

使用图神经网络来对搜索结果多样化排序任务进行建模的思路^[19-21]已经得到广泛关注,但以往使用的传统图结构中的边都是 2 个节点之间的关系,而超图中的边可以连接 2 个或多个节点,更能表达查询文档之间的复杂关系。

传统方法直接从查询中提取静态子主题,可能与文档的真实子主题分布存在差异。为解决这一匹配问题,OUYANG 等人^[38]提出了 HGDIV 方法,该方法利用超图构建文档及其子主题之间的关系,从候选文档动态挖掘子话题,并不依赖查询语句。HGDIV 构建超图的具体方式如图 7 所示,首先,使用 k -means 聚类算法将候选文档集合划分为多个子集 $D = \{d_1, d_2, \dots, d_n\}$,并为每个子集构建超图集 $B = \{b_1, b_2, \dots, b_n\}$,不同的超图对应表示不同的子主题。其次,利用 k 最近邻 k -NN (k -Nearest Neighbor)算法为每个文档构建各自的子主题集 $GC = \{c_1, c_2, \dots, c_n\}$,以模拟文档的子主题分布。总体而言,构建超图集 B 是为了模拟全局子主题分布,构建超图集 GC 是为了模拟每个文档的局部子主题分布。

在 HGDIV 中,除了通过构建超图对全局子主




Figure 7 Construction of hypergraph for HGDIV

图 7 HGDIV 的超图构建

题分布建模外,还会在超图中随机挑选节点,采用节点卷积和超边卷积的方法聚合各超图的信息,最后通过整合各个超图中包含的子主题特征得到全局子主题的分布。局部子主题通过对超图 B 中节点进行卷积的方式得到每个文档各自子主题的分布。

HGDIV 通过全局与局部 2 种不同方式对子主题建模以更好地表达各个子主题,也能更好地区分不同文档。通过这种方式可以挖掘到更多精细化的多样性特征,为解决搜索结果多样化排序问题提供了不一样的解决方案。

4.2.5 HAD 方法

DENG 等人^[39]为搜索结果多样化任务提出了一种新颖的基于层次注意力框架的搜索结果多样化排序方法 HAD (Hierarchical Attention framework for search result Diversification)。这一方法的核心思想是通过将文档内和文档间的交互结合起来进行多粒度文档建模,从而更精确地测量文档的子主题覆盖情况。具体来说,HAD 首先将文档分割成多个段落,并通过关键实体的选择来提取文档的主要内容。接着,利用堆叠交互块来加强段落和文档的表示,其中包括文档编码器和序列编码器,它们通过多头注意力机制捕获文档内部和文档间的复杂关系。

HAD 利用实体识别工具如 TagMe 对文档中的实体进行标注。TagMe 能够识别文本中的实体,并提供实体的概率得分,用于判断实体的重要性。HAD 将选择最重要的实体来表示文档内容并进行编码作为后续的重要特征,这不仅考虑了文档内部的语义关系,还考虑了文档间的语义差异。此外,HAD 引入了段落感知的文档-子主题信息,设计多层堆叠交互块,每层包括文档编码器和序列

编码器,文档编码器捕获文档内部段落之间的关系,通过文档内的注意力和多头注意力机制获取上下文感知的段落表示。序列编码器则使用同样的注意力机制层来增强不同候选文档间的交互。最终,通过一个多层感知机结合多样性特征和相关性特征,生成文档的最终排名分数。

HAD 通过引入层次注意力框架,使用多粒度信息交互以更准确地测量文档的子主题覆盖率,有效提升了搜索结果的多样化表现,但实体提取工具的性能对最终的多样化效果有较大影响,需要高质量的实体提取工具。

5 搜索结果多样化排序评价指标

在搜索结果多样化排序任务中,研究人员提出了多种多样性评价指标,目的是评估文档列表的内容不相似性和非重复性,以量化排序列表整体的多样性水平。多样性排序评价指标有别于传统信息检索中仅关注单个搜索结果与查询的语义相关性的做法,它们需要在相关性和多样性之间取得平衡,同时考虑覆盖查询的多个方面以满足不同用户的信息需求。此类指标中出现了一些新概念,如覆盖率、新颖性和惊奇度等,以更全面地评估用户体验。下面将对搜索结果多样化排序任务中的一些评价指标分别进行介绍。

5.1 子主题召回率

子主题召回率^[44]是衡量搜索结果列表前 k 个文档对查询子话题被覆盖的程度,该评价指标常用于评价信息检索领域多样化排序任务的性能。子主题召回率定义为结果序列中覆盖的子主题数量和查询子主题总数量的比值,该指标的计算方式如式(15)所示:

$$S\text{-Rec}@k = \frac{|\bigcup_{i=1}^k S(d_i)|}{|Subtopic|} \quad (15)$$

其中, $S(d_i)$ 为文档 d_i 覆盖的子主题集, $Subtopic$ 为当前查询包含子主题的总集, $|\cdot|$ 为集合求基数运算。子主题召回率强调奖励选择当前尚未覆盖的子主题,但没有考虑结果序列的排序。

5.2 α -nDCG

信息检索和推荐中的大多数指标,如平均精度均值 MAP (Mean Average Precision) 和归一化折扣累积增益 NDCG (Normalized Discounted Cumulative Gain)^[45],都假设每个文档的相关性可以独立于其他文档进行判断。然而,这种假设忽略了文档之间的冗余,可能会导致不准确的评估。

NDCG 是最常用的评价搜索结果排名质量的指标之一,但由于 NDCG 只关注列表文档的相关性,因此 CLARKE 等人^[29]提出了 α -nDCG,一个用于评估信息检索系统多样性和相关性的指标,它通过平衡相关和非冗余项来实现。具体来说, α -nDCG 定义了文档的增益效用 (Gain),假设文档子主题之间是相互独立的,并且具有同等的相关性,它对新发现的子主题进行奖励,多余的子主题将会被惩罚。增益效用的具体计算方式如式(16)所示:

$$Gain(d_k) = \sum_{i=1}^{n_i} r(d_k | t_i) (1 - \alpha)^{c(k, t_i)} \quad (16)$$

其中, n_i 为查询子主题的总数量, $r(d_k | t_i)$ 判断第 k 个文档 d_k 和子主题 t_i 是否相关, $c(k, t_i)$ 是在列表 k 排名内包含子主题 t_i 文档的数量, α 表示为对冗余子主题的惩罚因子,其值通常设置为 0.5。与此同时,文档的增益效用还会随着排序位置的深入而降低, α -DCG 使用 lb 折扣函数进行相应调整。通过计算每个位置文档的 Gain 从而得到结果序列的 α -DCG 值,其计算方式如式(17)所示:

$$\alpha\text{-DCG}@K = \sum_{k=1}^K \frac{1}{\text{lb}(k+1)} \cdot Gain(d_k) \quad (17)$$

不同查询之间对返回结果序列的长度可能不相同,使用 α -DCG 作评价指标会不利长度较短的结果序列的评估。为了方便对具有不同长度的查询结果序列进行可比性分析,本文在 α -DCG 的基础上进行了归一化 (Normalization) 处理形成 α -nDCG,这使得 α -nDCG 的取值介于 0~1 之间,使用式(18)进行计算:

$$\alpha\text{-nDCG}(Q, k) = \frac{\alpha\text{-DCG}(Q, k)}{\alpha\text{-DCG}(R, k)} \quad (18)$$

其中, Q 为当前预测结果序列, R 为按照多样性评分从大到小进行排序的结果序列,即为最理想序列的结果列表。

5.3 ERR-IA

瀑布式用户浏览模型是一种用于预测用户未来浏览行为的模型,用户最初会访问一个页面,然后根据该页面的内容,再访问另一个页面,依此类推。意图感知 IA (Intent Aware)^[46]的期望倒数排序 ERR-IA (Expected Reciprocal Rank-Intent Aware)^[30]结合了交互式信息检索中的期望倒数排序和子主题的概念。它假设文档和查询的相关性有等级之分,用户一旦看到一个或多个高度相关的文档后会有更大可能停止查看后续的文档。在位置 r 停下来概率 PP_r 的计算方式如式(19)所示:

$$PP_r = \prod_{i=1}^{r-1} (1 - R_i) R_r \quad (19)$$

其中, R_i 表示用户在结果列表中第 i 个位置需求得到满足的概率, 通常使用文档与查询的相关度等级函数来实现。如假设文档与查询的相关性 g 划分为不同等级, 其中 $g \in \{0, 1, \dots, g_{\max}\}$ 。一个常见的相关度得分函数如式(20)所示:

$$R_i = R(g_i) = (2^{g_i} - 1) / 2^{g_{\max}} \quad (20)$$

ERR 的计算如式(21)所示:

$$ERR = \sum_{r=1}^n \varphi(r) PP_r \quad (21)$$

其中, $\varphi(r)$ 可以是任意一个基于位置 r 的函数, 该函数满足 $\varphi(0) = 1$, 且 $\varphi(r)$ 的值随 r 的增大逐渐减小到 0, 如 DCG 中所使用到的 lb 折扣惩罚函数。

意图感知指标也常用于搜索结果多样化任务中, 它假设每个查询中有多个子主题, 在考虑优化多样性时不仅需要尽可能多地覆盖不同子主题, 同时不同子主题需要有不同的权重 $P_r(i|q)$, 从而对每个子主题的重要程度进行区分。ERR-IA 的计算如式(22)所示:

$$ERR-IA = \sum_i P_r(i|q) ERR_i \quad (22)$$

作为一种衡量搜索结果排序质量的指标, ERR-IA 考虑了用户浏览行为和假设意图, 能够更准确地评估搜索结果的相关性和多样性。其独特之处在于能够捕捉用户点击行为的不确定性, 从而提供更全面的搜索结果评估。同时 IA 指标的思想也能应用到其他的多样化评价指标中, 如 MAP、nDCG 等。

5.4 NRBP

新颖性排序偏差准确率 NRBP (Novelty and Rank-Biased Precision)^[47] 结合了 α -nDCG^[29] 与排序偏差准确率 RBP (Rank-Biased Precision)^[48], 融合了两者对用户浏览行为的建模。RBP 假设用户发出查询后, 按顺序从顶部开始浏览结果列表, 在读取第 1 个文档后用户会有 β 概率对结果不满意而选择阅读第 2 个文档, 此时他有 $1 - \beta$ 的概率会对第 2 个文档满意并停止往下翻看, 否则他将继续以恒定的概率依次往下阅读。NRBP 假设查询具有不同的子主题, 通过前面文档中的子主题覆盖情况来衰减新文档中相同子主题的增益贡献, 用于评估结果列表的新颖性和位置加权的相关性。NRBP 的具体计算如式(23)所示:

$$NRBP = \frac{1 - (1 - \epsilon)\beta}{N_s} \times$$

$$\sum_{k=1}^{\infty} \beta^{k-1} \sum_{i=1}^{N_s} r(d_k | t_i) (1 - \epsilon)^{c(k, t_i)} \quad (23)$$

其中, N_s 为当前查询的子话题总数量; $r(d_k | t_i)$ 表示为当前文档 d_k 是否和子主题 t_i 相关; $c(k, t_i)$ 表示当前列表前 k 位中包含子主题 t_i 的文档数量; ϵ 与 β 是 $0 \sim 1$ 的实数 ($0 < \epsilon, \beta < 1$), ϵ 表示对用户判断一个文档是否相关的一致性, 它描述了人工判断主观性、误判等因素的影响, β 表示用户持续浏览下一篇文章的概率, β 越大, 表示用户有更大概率继续浏览下一篇文章, 意味着用户浏览更广泛, 更愿意看更多结果。 ϵ 和 β 的组合反映了用户在浏览深度和广度上的权衡。NRBP 通过调整这 2 个参数, 可以模拟不同类型用户的浏览行为。文档的新颖性贡献度量由 2 部分构成: 一部分为文档关联度 $r(d_k | t_i)$, 另一部分为新颖性下降因子 $1 - \epsilon$ 的 $c(k, t_i)$ 次方, 二者结合实现了子主题新颖性随着排序位置靠后以及子主题重复出现后的衰减程度。

值得注意的是, α -nDCG 选择使用截取前 k 个文档的方式来评价返回结果的质量, 而 NRBP 则直接建模用户查看相关文档的预期数量, 更多的是一个总体性指标, 说明了整个返回结果的多样性, 提供了一种新的用户浏览模型和效果评价框架。

5.5 NDCU

YANG 等人^[49] 对 NDCG 提出改进, 在 NDCG 原有的增益 (Gain) 上进行改进, 改为用于评估当前文档的效用 $U(\text{Utility})$ 。他们将搜索系统的效用定义为用户在获取有用信息层面的收益与用户在时间和精力层面的损失之间的差值。文档 d_k 的效用 $U(d_k)$ 用式(24)表示:

$$U(d_k) = \text{Gain}(d_k) - \text{Loss} \quad (24)$$

其中, $\text{Gain}(d_k)$ 的计算方式与式(16)中 $\text{Gain}(d_k)$ 的计算方式相同; Loss 通常被设计为一个常数, 表示用户浏览阅读搜索系统返回的文档时产生的恒定成本。

DCU@K 的计算如式(25)所示, 它与 α -DCG@K 的计算方式大体相同。归一化过后的 NDCU 定义为 DCU 与理想序列的 DCU 之比, 其计算如式(26)所示:

$$DCU@K = \sum_{k=1}^K \frac{1}{\text{lb}(k+1)} \cdot U(d_k) \quad (25)$$

$$NDCU(Q, k) = \frac{DCU(Q, k)}{DCU(R, k)} \quad (26)$$

其中, Q 为当前预测结果序列, R 为按照多样性评分从大到小进行排序的最理想序列的结果序列。

5.6 D-M 与 D#-M 指标

SAKAI 等人^[50]提出 D-指标 D-M(D-Measure) 与 D# 指标 D#-M(D#-Measure), 它们假设每个查询对应多个子主题, 每个子主题对应不同的概率权重值, 解决了传统 IA 指标非规范化、容易忽略小概率权重子主题的问题。D-M 指标通过统计第 r 个文档与所有子主题的相关度 $g_i(r)$, 结合每个子主题不同的概率权重值 $P_r(i | q)$, 构成该文档的全局增益 GG(Global Gain), 其计算如式(27)所示:

$$GG(d_r) = \sum_i P_r(i | q) g_i(r) \quad (27)$$

通过使用全局增益方式代替原有许多评价指标简单对文档计算的增益, 如式(28)为由 DCG 改进后的 D-DCG 指标, 这能够更好地表达多样化效果。

$$D-DCG@K = \sum_{k=1}^K \frac{1}{\lg(k+1)} \cdot GG(d_k) \quad (28)$$

D#-M 指标是在 D-M 指标的基础上, 引入了子主题召回率, 使用 γ 参数控制将子主题召回率与 D-M 指标进行线性组合, 以明确地奖励排名结果以覆盖更多查询的子主题, 可以将不同的 D-M 进行改进为 D#-M 指标。D#-M 的定义如式(29)所示:

$$D\#-M = \gamma \cdot S-rec + (1 - \gamma) D-M \quad (29)$$

其中, $S-rec$ 表示意图召回率。

5.7 RBU

AMIGÓ 等人^[51]总结了搜索结果多样化排序任务所需要考虑的多种变量影响, 如排序位置深度、文档相关性等级等等, 列出了包含相关性与多样性共 10 个形式的约束条件。他们发现现有评价指标都至少能够满足搜索结果多样化的 1 种约束条件, 但却没有一个评价指标能够同时满足所有约束条件。基于此, 他们在 RBP^[48]的基础上使用公理分析法进行改良, 提出了一种可以同时满足所有约束条件的评价指标, 即排序偏差效用 RBU(Rank Biased Utility)^[51], 其结合了多种评价指标的优势, 同时考虑了所有约束条件。

RBU 对文档的效用进行以下定义: 用户探索下一篇文章的概率为 p , 用户从文档 d_j 中获得查询子主题 t 的效用的概率为 $r(d_j, t)$, 查询不同的子主题分别有各自权重 $w(t)$, 因此文档 d_i 的效用 $U(d_i)$ 可以表示为式(30):

$$U(d_i) = p^i \sum_{t \in T'} w(t) r(d_i, t) \prod_{j=1}^{i-1} [1 - r(d_j, t)] \quad (30)$$

RBU 考虑到用户浏览过程中在看到一不相关文档时会带来失落感, 这种情况下带来的不良影响, 需要估算文档效用损失 e , 通常设置 e 为常数。RBU 的计算如式(31)所示:

$$RBU@K = \sum_{i=1}^K U(d_i) - p^i e \quad (31)$$

5.8 EBR 与 iRBU

SAKAI 等人^[52]认为一个评价指标的好坏更应该注重在衡量实际应用中能否给用户带来良好的体验感受, 虽然 RBU 通过设计满足 10 种约束条件的方法提升了用户多样化体验, 但对其中每个约束条件对用户来说是否重要、是否与用户感知保持一致等问题发出质疑。在此基础上, 他们提出了新的评价指标, 即期望混合比率 EBR(Expected Blended Ratio)^[52]与意图级别的排序偏差效用 iRBU(intentwise RBU)^[52]。

EBR 融合了 ERR 指标的用户停止浏览概率与 Q 指标中的混合比率效用函数的思想。首先, 采用了 ERR 指标中用于计算用户在位置 r 停止继续浏览的概率 PP_r , 其具体计算方式如式(19)中的 PP_r 所示, 此处不再赘述。其次, 通过设计使用归一化混合比率效用函数 $BR(\cdot)$ 来估算当前序列的实际效用, 其计算如式(32)所示:

$$BR(r) = \frac{C(r) + \phi \cdot cg(r)}{r + \phi \cdot cg^*(r)} \quad (32)$$

其中, r 为当前文档序列长度; $C(r)$ 表示序列前 r 位相关文档的数量; $cg(r)$ 表示排序结果序列前 r 位文档的累积增益; $cg^*(r)$ 为理想序列前 r 位文档的累积效益; ϕ 为平滑系数, 其值通常取 1。综合 BR 与 PP_r , 得到 EBR 的计算方式如式(33)所示:

$$EBR@k = \sum_{j=1}^k PP_r(j) BR(j) \quad (33)$$

iRBU 则融合了 ERR 和 RBP 指标的思想, 采用了如上文所述的用户停止浏览概率 PP_r , 而归一化效用函数只考虑了文档的排名位置, 没有考虑文档的相关性, 设计使用一个常数 h 的 r 次幂作为文档的效用函数, 这种方式强调随着用户浏览深度增加需要不断消耗精力, 因此会对文档效用造成损耗。iRBU 的计算方式如式(34)所示:

$$iRBU@k = \sum_{j=1}^k PP_r(j) h^j \quad (34)$$

5.9 评价指标总结

多样化评价指标在搜索结果多样化排序任务的性能评估中扮演着重要角色, 它们是用于衡量多

样化搜索结果方面性能的重要标准,旨在评估方法解决搜索结果多样化排序任务时能否在满足用户对查询相关性需求的同时,尽可能广泛地覆盖不同用户的查询意图,提供内容丰富、多样化的搜索结果以改善用户体验,从而提升用户满意度。

表3总结了各个搜索结果多样化评价指标的特点或可解决的问题。针对不同的实际应用场景,可以有针对性地使用相关评价指标,这样将会更加符合用户的期望以增强用户的实际体验。

Table 3 Diversity metrics and its characteristics

表3 多样性评价指标及其特点

指标名称	特点或解决的问题
<i>Subtopic recall</i>	衡量结果列表覆盖查询子主题的程度,奖励选择新子主题,但没有考虑列表排序质量
α - <i>nDCG</i>	在 <i>nDCG</i> 基础上加入因子 α 惩罚重复出现的子主题,以平衡相关性和非冗余性
<i>ERR-IA</i>	建模用户瀑布浏览行为模式,区分不同子主题权重,优化文档顺序与子主题权重匹配程度
<i>NRBP</i>	通过新颖性的衰减机制建模子主题被多次出现后带来的效用下降,同时结合用户浏览广度和深度,通过不同参数模拟不同类型用户的浏览行为
<i>NDCU</i>	在 <i>NDCG</i> 基础上,在评估文档效用时考虑用户读取文档所需的时间成本,以更准确评估文档对用户的真实效用
<i>D-M</i> 、 <i>D#-M</i>	<i>D-M</i> 与 <i>D#-M</i> 通过区分不同子主题的权重,对多样化排序结果进行更规范化的评估; <i>D#-M</i> 指标进一步引入召回率以明确奖励覆盖更多子主题
<i>RBU</i>	通过定义搜索结果多样化需要满足的 10 种约束条件,综合考虑了多种因素对用户体验的影响,提供了一种更全面的评估方法
<i>EBR</i>	融合 <i>ERR</i> 浏览模型和 <i>Q</i> 指标函数,使用混合比率作为效用函数,同时考虑了已获相关文档的数量和文档本身的排名,可以处理文档多级相关性。
<i>iRBU</i>	融合了 <i>ERR</i> 和 <i>RBP</i> 指标的思想,在停止概率上体现了相关性和用户满意度的衰减,而在效用函数上只关注了文档排名位置,避免了相关性对文档效用的影响

综上各节中所阐述的搜索结果多样化评价指标可看出,这些评价指标涉及搜索结果的多个方面,包括相关性和多样性,多样性可通过诸如覆盖度、新颖性、惊奇度、意图感知、效用和用户体验等方面来体现,这些指标共同构成了评价多样化搜索结果性能的综合体系。不同的搜索结果多样化评价指标各有优缺点和适用场景。在实际应用中,具体取决于搜索结果多样化排序任务的设计目标和用户需求,可以根据具体目标 and 需求选择合适的评价指标来评估搜索结果多样化排序任务的性能。同时,也需要注意到评价指标的优势、局限性和不足之处,以便更全面地了解各方法在完成搜索结果多样化排序任务时的实际表现。

6 搜索结果多样化排序数据集和方法性能对比

6.1 搜索结果多样化排序数据集

TREC Web Track 是评估大规模 Web 数据集检索技术的重要平台,自 2009 年以来,它通过引入多样化任务,推动了搜索结果多样化的研究。该多样化任务要求系统返回一个有序的页面列表,这些页面共同为查询提供完整的覆盖,同时避免结果中的重复内容。ClueWeb09 数据集是 TREC Web Track 的核心资源,由卡内基梅隆大学的语言技术研究所创建,来自于 TREC Web Track 2009—2012^[53-56]。ClueWeb09 数据集包含约 10 亿个网页,涵盖了 2009 年初起从 Web 上爬取的多种语言内容,总计约 25 TiB 的未压缩数据。NIST 创建并评估了 200 个新查询,其中 198 个用于搜索结果多样化任务(2 个没有子主题判断的查询被删除)。这些带有多多样性的查询分别包含 3~8 个人工标注的查询子主题,并且查询中的子主题都具有相同的权重。

NTCIR-9 INTENT^[57] 是在多个研究中被用来评估信息检索系统性能的一个新任务,特别是在多样性和子主题挖掘方面。其中 SogouT 文档集合是由清华大学与搜狐联合实验室在 2008 年抓取并发布的中文文档集合,用于 NTCIR-9 INTENT 任务的中文子任务。ClueWeb09-JA 文档集合是由卡内基梅隆大学语言技术研究所从 ClueWeb09 集合中提取的日文文档集合,用于 NTCIR-9 INTENT 任务的日文子任务。

目前,由于 TREC Web Track 数据集具有较为丰富的子主题信息,研究人员更倾向于使用 TREC Web Track 数据集。

6.2 搜索结果多样化排序方法性能分析

为了对比分析近 5 年来搜索结果多样化排序领域新提出的方法的性能,本文统计了图 2 中所汇总和列举的这些主要方法的模型在 TREC Web Track ClueWeb09 数据集上的运行结果,并根据模型检索到的排名结果的前 20 个文档使用多样性评价指标 *ERR-IA*、 α -*nDCG*、*NRBP* 进行系统性评估,相关实验结果已汇总在表 4 中,这些结果的数据均来自各模型所对应的文献。

总览表 4 中统计的各模型各评估指标的结果,可以发现:近 5 年来,各研究团队在搜索结果多样化排序领域进行了各类方法的广泛探索和尝试,并

Table 4 Performance comparison of major methods of diversified ranking of search results in the latest 5 years

表 4 近 5 年主要搜索结果多样化排序方法性能对比

类别	选取方式	方法	ERR-1A	α -NDCG	NRBP
隐式	贪婪式	MatchingDIV	0.366	0.467	0.334
		Graph4DIV	0.370	0.468	0.338
		GAT-DIV	0.380	0.476	0.351
		KEDIV	0.390	0.485	0.362
		PAD	0.386	0.482	0.357
	全局式	Query-Transformer	0.354	0.454	0.322
		CL4DIV	0.393	0.486	0.364
显式	贪婪式	DVGAN	0.367	0.465	0.334
		GDESA	0.369	0.469	0.337
	全局式	DESA	0.363	0.640	0.332
		HGDIV	0.380	0.475	0.351
		DUB-SRD	0.399	0.508	0.374
		HAD	0.387	0.480	0.361

成功实现了显著的性能提升。从评估指标来看,无论是显式方法还是隐式方法,均展现出了优秀的性能。特别是 DUB-SRD 显式模型,其卓越的性能可能归功于其采用的 BERT 编码技术。与传统的 doc2vec 方法相比,基于 BERT 的编码方式能够更精确地捕捉文档的语义内容,并提高了从文本中提取子主题的准确性。

此外,隐式方法 CL4DIV 通过引入对比学习机制,显著提升了文档表示的能力与鲁棒性,是多样化能力最佳的隐式模型。实验结果强调了高质量文档向量表示在模拟文档子主题覆盖情况中的关键作用。从理论角度审视,显式模型因其能够直接对多样性进行建模,通常被认为在搜索结果多样化方面具有潜在的优势。然而,在实际应用中,许多显式模型的性能并未显著超越隐式模型。这一现象可能由于显式模型在子主题提取方面的潜力未能得到充分发挥。例如,DUB-SRD 模型通过采用先进的子主题提取技术,有效地利用了显式子主题信息,从而在性能上取得了显著提升。显式模型的子主题建模能力若能得到更深入的开发和应用,将有可能显著优化搜索结果的多样性。未来研究可以进一步探索如何更有效地集成和利用显式子主题信息,以期实现搜索结果多样化的进一步改进。

在搜索结果多样化排序的研究中,使用图结构建模文档及查询之间的关系也是研究人员的重点关注对象。这主要得益于图结构天生适合处理搜

索结果多样化排序任务的特性。图结构能够自然地表示文档和查询之间的复杂关系,通过节点和边来捕捉文档之间的相似性和主题关联。具体来说,图结构模型可以通过构建查询-文档图,利用图中的边权重表示文档之间的相似度,从而在搜索结果中引入多样性。此外,基于图结构的算法,如图卷积网络和图注意力网络,能够有效地利用图结构信息,进一步提高多样化搜索结果的质量。

此外,全局选取多样性文档序列的方法已经引起广泛的关注。这一方法促进了各个文档间的表示信息交互,且无需维护已选文档列表。它直接依据文档得分进行一次排序,从而得出最终的多样性排序结果。这种方法不仅有效缩短了模型的运行时间,还显著提升了达到全局最优排序结果的概率。通过这种方式,能够以更高的效率和更优的效果来实现搜索结果的多样化排序。

7 搜索结果多样化排序应用

随着搜索结果多样化排序方法的不断发展,其应用领域也越发广泛,从传统的搜索引擎扩展到更多更为细致的推荐与搜索等领域。

7.1 搜索结果多样化排序实际部署

搜索结果多样化排序对用户搜索体验起着重要作用,但如何在实际中部署落地也值得重点关注。Airbnb 是国际知名酒店预订网站,其对多样性的效果也是十分关注,早在 2015 年就尝试解决这一难题,在经过设计基于特征的评分函数、推出梯度增强决策树模型以及基于类别的多样化排序之后发现依然不能取得让人满意的结果。文献[58]发现:基于对级(pairwise)排序学习的方法存在只考虑单个房源预订概率的问题,忽略了搜索结果中房源之间的相关性,导致排名缺乏多样性。为了解决这个问题,ABDOOL 等人^[58]于 2020 年提出了一种新的基于多因素考量的排序框架,利用循环神经网络生成查询上下文的嵌入,综合考虑查询、用户和房源特征。通过这种方法,团队显著提高了搜索结果的多样性,使得用户在搜索时能够看到更多不同类型的房源,提供了更丰富的选择。这一方法在实际应用中取得了显著成效,提高了预订量和用户满意度。

随后,在 2023 年,他们对以往工作没有考虑样本之间的关系,忽略了房源之间的竞争和相关性进行改进,没有采用以往传统排序学习的点级(pointwise)学习方式,转为使用基于列表(list-wise)的学习方式,以更好地考虑房源之间的相关

性和竞争关系^[59]。同时,在 Airbnb 的研究中,其研究团队对用户的兴趣和偏好进行了深入分析,发现大部分用户的兴趣和偏好高度一致,具体而言,大多数用户倾向于选择经济实惠的房源,显示出明显的集中趋势。此外,他们对以往的贪婪选择过程中度量当前文档与已选文档之间相似性的方式进行了优化。新的多样化排序方法通过建立多个神经网络模型来实现排序的优化。具体来说,这些模型不仅考虑单个房源的属性(如价格、位置、设施等),还综合考虑已经排序的房源属性,从而动态调整排序结果。通过这种方法,模型能够减少相似房源的排序,提高搜索结果的多样性。例如,通过减少位置相近房源的排序,用户能够看到更多不同位置的房源,增加了选择的多样性和满意度。通过在线 A/B 测试和离线测试,Airbnb 的预订量增加了 0.29%,总预订价值增加了 0.8%,验证了新的多样化排序方法在提高预订量和搜索结果多样性方面具有有效性,并有效提升了用户满意度。

小红书将推荐问题建模为时间序列分析,采用滑动谱分解的方法,通过张量分解考虑窗口内外的项目来更好地捕捉多样性,并设计了基于孪生网络(Siamese network)的项目表达学习方法,通过引入滑动窗口技术,结合时间序列分析,全面考虑用户在浏览长序列推荐内容时的多样性感知,用于在长尾场景下准确度量项目之间的相似性,联合学习内核矩阵以平衡准确性和多样性^[60]。

阿里巴巴从重排的角度出发提高推荐的多样性,提出了一种通用的基于感知的多因子序列多样化重排序 MPAD(Multi-factor sequential re-ranking with Perception-Aware Diversification) 框架^[61]。MPAD 使用顺序选择的方式以优化整个排序列表的准确性和多样性,同时根据用户的浏览历史,提出了通过基于图的聚类算法提取用户多尺度兴趣建模(宏观兴趣、微观兴趣)和基于感知的内核方法以捕捉个性化多样性,并设计了改进的双向序列行列式点过程 BS-DPP(Bi-Sequence Determinantal Point Process)方法。在标准的行列式点过程 DPP 方法中,物品准确性分数被认为是固定的,而在 BS-DPP 中,物品的准确性分数会随着用户浏览上下文的变化而变化,这更符合信息流场景中用户浏览连续项目时其兴趣会演化的特点,同时使得多样性的计算更加个性化,而不是简单基于物品的特征距离。

MPAD^[61]已经应用于淘宝网站中“猜你喜欢”服务中,并提升了 2.38% 的点击量,0.62% 的点击

通过率以及 0.48% 的总商品交易额,用户的停留时间也增加了 1.95%,验证了 MPAD 能够同时提高推荐结果的项目准确性和多样性,并能很好地平衡两者。

7.2 教育搜索

搜索即学习是近年来一个新兴研究方向,主要是研究如何利用搜索引擎和搜索过程来帮助用户学习新的知识和技能。它结合了信息检索、教育科学、认知科学等跨领域的研究视角。YIGIT-SERT 等人^[62]将搜索多样化技术应用到教育搜索领域。与传统搜索引擎不一样,在教育搜索引擎中,需要将结果多样化应用于多个维度,不仅是被检索文档覆盖的查询子主题层面,还需要考虑文档类型和适合人群智力水平等维度。他们扩展了 xQuAD^[63]、PM-2^[64]和 R-LTR^[12]等搜索结果多样化排序算法,提出了对应框架以处理多个维度,通过为每个维度计算维度重要性来考虑不同维度下各个方面的覆盖程度。

在真实教育搜索引擎的日志基础上创建的全新测试集进行实际应用后,文献[62]提出的方法能够在排名靠前的结果中展现多种类型的文档、教育层次和主题,并且在 ERR-IA 指标上,与传统的“扁平化”多样化方法相比,其提高了 2.6% 的种类展示率;与基于 BM25 的初始排名相比,有 15.1% 的显著提高。

7.3 学术搜索

传统信息检索系统的目标主要是最大化结果的相关性,但是仅仅关注相关性可能会导致一些不公平现象,例如少数群体的曝光份额过小。近年来,搜索引擎的公平性问题成为一个重要研究方向。McDONALD 等人^[65]将学术搜索场景下的公平排名定义为一个查询序列的重新排序任务。给定一个查询,目标是生成一系列排名结果,使不同作者群体获得公平的曝光机会。其关键思路是将公平排名看作是一个搜索结果多样化排序的问题。具体来说,基于学术论文作者的特征将文档分组,作为多样化处理的不同“层面”;然后采用多样化排序方法来提高各组在排名结果中的曝光份额。该文评估了 3 种多样化方法:基于相似性的 MMR^[7]方法,显式建模查询子主题的 xQuAD^[63]方法和 PM-2^[64]方法,并在 2019 年和 2020 年 TREC 的公平排名测试集上进行评估,结果显示,与仅关注于提升相关性的基线方法相比,多样化排序方法可以明显提升性能,实现更加公平的作者群体曝光,表

明了搜索结果多样化排序是实现作者群体公平曝光的有效途径,但也需要进一步研究如何有效集成多重属性信息来提高多样化排序的效果。

7.4 个性化搜索

个性化搜索和搜索结果多样化排序都是处理查询歧义的方法,但大多独立地被研究,少数结合二者的研究也存在只考虑用户兴趣相关子话题的局限性。中国人民大学窦志成和文继荣教授团队^[66]指出:搜索结果个性化旨在根据不同用户的偏好为其定制结果,但存在冗余的结果和对用户意图的不完整捕捉的局限性;而搜索结果多样化旨在返回尽可能多地涵盖与查询相关方面的结果,它提高了多样性,但失去了个性化,无法返回用户想要的确切结果。搜索结果个性化和多样化可以相互补充,并可带来更令人满意的重新排序结果。为此,他们提出了一个新的框架 PnD,以合理地整合搜索结果个性化和多样化。其次,他们在文献^[67]中还基于大规模搜索日志,在不需要事先确定子话题的情况下,采用了一种隐式的方式来评估文档的新颖性和差异性,提出了同时优化个性化和多样化的方法,对文档的个性化和多样化得分进行计算,再根据查询与用户配置文件的相似度动态聚合二者,直接提高了用户对搜索结果的满意度。WANG 等人^[68]提出整合个性化搜索和搜索结果多样化的框架 ExpliPS。与基于隐式的多样化思路不一样,ExpliPS 使用显式的方法结合查询子主题来进行多样化,利用查询子主题明确地建模用户意图,从而提供解释性更强和强鲁棒的搜索结果排序。

7.5 搜索结果多样化排序应用综合分析

在处理推荐和搜索结果多样性的问题上,不同方法各有特点并适用于不同的应用场景。DPP 和 MPAD 框架^[61]主要应用于社交媒体和电商平台,通过优化相似度矩阵和结合多种模型来实现推荐结果的多样化,适用于用户兴趣多变且数据量大的场景。而多维度多样化方法更适用于教育搜索引擎,通过在主题、文档类型和知识水平等多个维度上进行结果的多样化呈现,提供全面的学习资源。显式偏好多样性模型通过显式收集和利用用户偏好信息,动态调整推荐结果,适用于需要用户频繁反馈的场景。结合用户个性化需求的多样性推荐算法则是利用用户历史行为数据,确保推荐结果既符合用户兴趣又具有多样性,适用于电商和社交媒体平台的个性化推荐。尽管这些方法在理论上都

具有良好的效果,但在实际应用中需要根据具体情况进行调整和优化,以确保其有效性和适用性。

8 搜索结果多样化排序展望

上文对搜索结果多样化排序的背景、方法、评价指标等方面进行了总结,同时对搜索结果多样化排序数据集和现实应用进行了概述,通过总结以上信息,本文认为未来的搜索结果多样化排序任务研究将会在以下几个方向上进行优化和拓展。

8.1 基于大语言模型的子主题挖掘质量优化

相较于隐式多样性排序方法,显式多样性排序方法有着更优秀的性能上限,然而很大程度上受限于子主题的质量,因此如何挖掘良好的子主题一直是研究人员重点关注的问题。研究人员已经提出了多种挖掘子主题的方法,在实际研究中较为常用的是使用 Google Suggestions 提供的来自搜索引擎的查询建议作为子主题的外部挖掘方法,但这种方法依赖大规模日志数据,对长尾查询无法提供良好的建议词,可能导致子话题覆盖不够。近年来,大语言模型 LLM (Large Language Model),如 BERT、GPT-4 等,采用机器学习技术,通过对海量文本数据的训练以产生模型,已经在自然语言生成方面展现了强大能力,这些能力可以显著提升挖掘子主题的质量和效率,为多样化搜索结果中的子主题挖掘提供了新思路。具体而言,可以利用 LLM 对知识的理解与生成能力,通过给定查询词作为提示,生成相关的子主题词汇。相比依靠查询日志等外部资源进行词汇获取,基于大语言模型来挖掘子主题的方法可以产生语义更加流畅、上下文更加相关的词汇作为候选子主题。更详细地说,LLM 通过给定的查询词作为生成提示,可以快速自动输出遵循语言逻辑的相关词汇,无需人工构建查询和子话题之间的映射,同时可以有效屏蔽与查询无关的词汇。随着查询的变更,LLM 可以从不同角度生成子主题词汇,以保证结果的多样性。利用大语言模型预训练得到的词向量,可以提取出文本中与主题紧密相关的关键词,有助于后续子主题的挖掘。同时,基于大语言模型可以提供更精确的文本间相似度度量以帮助优化聚类算法的效果,可以更好地发现不同主题词或关键词之间的关联关系,并以此作为挖掘子主题的重要依据;可以对文本数据进行更深层次的处理和分析,从而挖掘出更加精细的子主题。相比计算复杂的话题模型,LLM 的大规模预训练有着更高的效率。但是,LLM 生成的子主题词汇也可能存在内容无

关、重复性高、词汇间关联性不强等问题。因此 LLM 作为外部资源输入,需要后续处理来提升质量和增强文档关联性。

对于子主题的挖掘,除了可以从查询作为出发点,并使用查询日志、采用大语言模型等技术外,也有研究人员从候选文档内部出发对子主题进行探索^[30,36],且已经取得了不错的效果,如何设计出更优秀的子主题提取器将会受到更多关注。随着 LLM 技术的不断发展和完善,其在挖掘子主题方面的应用前景广阔,有望更进一步提升子主题挖掘的质量。

8.2 基于生成式模型的搜索结果多样化排序方法探索

Google 在 2017 年提出的 Transformer 架构,通过自注意力机制显著提高了生成式模型的质量,这成为后来众多生成式模型如 ChatGPT 的基础。近年来生成式人工智能的发展极为迅速,从图像生成扩展到音频、视频、文本等模态的数据生成。生成式推荐系统也是研究人员关注的重点,相比传统的基于协同过滤、内容过滤等技术的推荐系统,生成式推荐系统的潜力空间巨大。研究人员针对生成式推荐提出了诸如基于扩散模型的各种范式 DiffRec^[69] 和 DreamRec^[70] 等。

目前,将生成模型应用于搜索结果多样化排序任务的探索还处于起步阶段,如多样化排序方法 DVGAN^[35] 等,仍存在训练不稳定、模式崩溃、收敛困难等问题。考虑到生成模型本身具有多样化生成的优势,因此将其应用于搜索结果多样化排序任务是合理的选择。将更多高质量的生成模型应用并适配到搜索结果多样化排序任务中,是值得进一步研究的方向。但需要注意的是,当前大多数生成模型因为庞大的语言模型,推理时间较长,难以满足在线低延迟搜索或推荐场景的需求。因此,如何在生成质量和生成速度之间达到平衡也是一个亟待解决的难题。

8.3 多模态搜索结果多样化排序方法探索

当今数据存储是多媒体和多模态的,文本、图像、视频和音频等不同模态的数据为用户提供多元化的搜索意义。随着多模态数据的快速增长,搜索引擎需要处理文本、图像、视频和音频等不同模态的复杂交互关系,以提供更加丰富和准确的搜索结果,这将促使搜索引擎或推荐系统等信息检索系统从单一模态向多模态融合发展。多模态数据之间的关系可以相互补充,从而提高搜索结果多样化排

序的准确率和多样性。例如,结合图像中的场景和物体信息,可以帮助理解文本描述的语义;语音转换的文本可以作为图像或视频内容的补充信息;等。目前已经有如 GoSearch 的人工智能搜索引擎,通过多模态搜索和 AI 核心技术,提供高效的信息检索体验,以减轻员工认知负担。可以预见,未来的搜索引擎或推荐系统将会迈向多模态化,以更好地满足不同用户的多样化信息需求。

8.4 检索增强生成技术与搜索结果多样化排序方法融合研究

近年来,检索增强生成 RAG (Retrieval-Augmented Generation) 技术^[71] 是人工智能领域的研究热点之一。它是一种新的自然语言处理系统结构,通过在神经网络生成模型中引入检索机制来实现生成能力的提升,目前常与大语言模型结合。RAG 包含检索、融合和生成 3 大模块,其中,检索模块负责提供相关外部信息,丰富生成模块的知识源,融合模块将检索结果和原用户输入文本融合,送入生成模块;生成模块接收检索内容进行语言理解和生成。检索模块作为 RAG 中的重要组成部分,应用搜索结果多样化排序方法可以为模型提供更为多样化的外部知识,从而提升最终生成结果的多样性。

RAG 技术和搜索结果多样化排序方法的融合潜力巨大。RAG 技术结合了检索和生成 2 种方式,利用大规模外部知识库,来生成更准确、更具针对性的回答。而搜索结果多样化排序方法则从大范围的查询结果中挖掘出覆盖不同角度和方面的信息,以满足各种不同用户的信息需求。例如,针对用户发出的查询语句往往较为模糊的现象,将用户的查询语句作为上下文,然后利用 RAG 模型中的外部知识源进行查询扩展。

通过融合 RAG 技术的检索-生成方法和搜索结果多样化排序方法,利用海量的知识库进行深度查询,同时提供多角度的回答,用户将从中获得更全面、更多样化、更有深度的答复,不仅满足其明确的查询需求,也可能挖掘出他们还未明确的潜在需求。然而,这种融合也面临一些挑战:首先,如何选择合适的知识库以适应不断增长和演化的信息需求,这需要技术的灵活性和扩展性;其次,如何合理地将某种搜索结果多样化方法融入 RAG 模型中,或者合理地将 RAG 模型的检索-生成方法融入搜索结果多样化排序方法中,以互相改进多样化性能,这需要深层理论的指导性;最后,如何确保系统的性能和效率,尤其是在面对大规模知识库和复杂

查询时,这需要技术的高效性和稳健性。

8.5 应用前沿深度学习技术设计搜索结果多样化排序方法

近年来,研究人员尝试应用图神经网络、基于深度学习的知识图谱等各种深度学习技术来提升搜索结果的多样化效果。图神经网络通过建模文档与查询之间的高阶语义关联,学习到更丰富的多样性特征表示。而利用知识图谱注入文档属性、功能、场景等结构化信息,则可以丰富内容理解和搜索与推荐的策略,产生更合理的多样化排序结果。可以预见,未来结合对比学习、对偶学习、迁移学习、元学习、知识蒸馏等不同的前沿技术及它们的混合技术,来实现跨域知识的快速迁移,以及丰富垂直领域推荐系统和搜索引擎的理解能力也存在着巨大的进步空间。

8.6 从信息检索不同处理流程提高排序结果的多样性

传统检索系统工作流程划分为文档召回、精排、结果重排序 3 个步骤,前文介绍的搜索结果多样化排序方法集中于对文档检索精排后的数据集在重排序的流程上提升多样化效果。显然精排后数据集的质量对重排序算法的效果也会产生影响。美团设计了应用于精排阶段的多样性感知列表信息融合和平衡加权损失 2 个多样性感知组件,提出了一个多样性感知深度排序网络,为重排序阶段提供了更多样化的列表^[72]。目前在召回和精排阶段对多样化的探索还相对较少。因此,在整个信息检索流程中同时提升多样性,可能会使应用系统产生更佳的结果多样化排序性能。

8.7 探索更能表达多样性排序的性能指标

在搜索结果多样化排序任务中,同时考虑相关性和多样性的性能指标 $ERR-IA$ 和 $\alpha-nDCG$ 等被广泛使用,但这些指标更多停留在对结果排序的评价上,对用户主体体验评价不足。YU 等人^[73]对现有常用评价指标进行分析,发现现有评价指标没有很好地捕捉内在多样性,同时对于子主题层次细腻度多样性没有得到地进行挖掘。SAKAI 等人^[52]通过收集用户的真实反馈对 30 个信息检索评价指标进行评估,实验结果表明大多数的意图感知指标并没有与用户多样性偏好评价形成一致性。未来,设计嵌入了交互反馈的指标或引入用户调查评价的指标将能更好地反映多样化对用户体验的提升,进而真实提升用户的多样化体验。

8.8 大规模多样化排序学习数据集的构建与更多应用场景的专用多样化排序学习数据集的构建

目前,搜索结果多样化排序任务在学术界中主要使用的多样性排序学习数据集是 TREC 2009-2012 Web Track 数据集。然而,该数据集仅包含不到 200 条查询以及约 4 000 个文档,这也说明了当前搜索结果多样化排序任务存在数据稀缺的挑战。

现有多样化排序学习数据集主要基于查询日志构建,质量参差不齐。未来,可在限定场景内,通过人工构建或机器辅助的方式,构建信息量更丰富,辅以其他模态信息的标准化、大规模、多样化的排序学习数据集,或是学习迁移应用现有文本匹配、推荐系统数据集集中的研究成果。这 2 类方案都将推动搜索结果多样化排序的深入研究。另外,针对特定应用场景收集真实用例,编制专用多样化排序学习数据集也是一个可行思路,这能直接反映业务的真实性需求,指导搜索结果多样化排序模型或方法在具体问题和实际应用中不断优化和拓展。

8.9 搜索结果多样化排序的可解释性研究

目前的搜索引擎和推荐系统已经普遍采用多种多样化排序算法,这些算法往往需要同时优化和平衡多个评价指标。但是,这种综合多个目标函数的排序算法也使得最终排序结果对一般用户来说并不透明,可解释性较差。如果搜索或推荐排序中的文档排位无法向用户清晰地传达排位产生的原因,用户就可能对排序结果的顺序合理性和可信性产生质疑,从而降低对搜索引擎或推荐系统的信任度。因此,提高多样化排序结果的可解释性和可理解性是搜索引擎和推荐系统面临的一个重要挑战。

具体来说,未来的研究可以尝试通过人机交互的方式来实现多样化排序的可解释性:可以设计让用户参与排序过程的交互系统,根据用户的即时反馈来调整算法的排序策略;也可以建立不同用户群体的行为模型,并根据模型给出个性化的排序解释。这样可以让用户对搜索结果多样性排序的考量因素一目了然,提高算法决策的透明度。此外,还可以设计对话式的搜索结果生成系统或采用可解释性强的机器学习方法来设计多样性排序算法,以提高排序结果的可解释性,在保证多样性的同时让每个结果的出现都可追溯、可解释。

8.10 拓展多样化排序方法的应用领域

多样化排序在很多互联网应用中发挥着重要

的作用,比如搜索引擎中的多样化搜索、电子商务中的多样化商品推荐、社交网络中的多样性好友推荐、抖音平台中的短视频多样性搜索和推荐、教育资源平台的多文本摘要等,都需要多样化排序技术来提升搜索和推荐等排序结果的多样性。生成式人工智能、大语言模型和检索增强生成技术等的爆发式发展,极大地促进了多样化排序在互联网搜索和推荐产品等场景中更为广泛的应用。例如,ZHANG 等人^[74]将搜索结果多样化方法应用于法律案件检索中。针对不同需求场景的多样化排序的难点在于如何将不同需求场景的实际情况与多样化排序方法有机融合,从而指导多样化排序方法的训练以获得一个能满足应用需求场景的更多样化的排序模型。

9 结束语

搜索结果多样化排序旨在生成能够覆盖查询中不同方面的结果来满足用户的多元化需求,在现实世界中有着广泛的应用。本文首先回顾了搜索结果多样化排序的定义、分类及方法发展。其次,基于模型是否对子主题显式建模划分为隐式方法和显式方法,并按照模型生成多样化结果序列的不同方式将其划分为贪婪式方法与全局式方法,并详细分析了近 5 年来各类别中的代表性方法。再次,对主流和新颖的多样化评价指标以及搜索结果多样化数据集进行了阐述与分析,并评估了主要搜索结果多样化排序方法的性能。然后,本文还概括了搜索结果多样化在搜索引擎、教育搜索、学术搜索等领域的应用情况。最后,展望了搜索结果多样化排序方法未来的几个研究方向,包括基于大语言模型提升子主题的质量,应用生成式模型、多模态、检索增强生成技术、前沿深度学习技术、多个处理流程等方面设计多样化排序方法以提升排序结果的多样性,设计新的多样化评价指标、构建大规模和专用多样化数据集、搜索结果多样化排序的可解释性及应用领域拓展等。希望本文工作能为学术界和工业界的相关研究人员提供一定的参考与借鉴,为搜索结果多样化排序领域更好更快的发展赋能。

参考文献:

- [1] SANDERSON M. Ambiguous queries: Test collections need more sense [C]//Proceedings of the 31st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, 2008:499-506.
- [2] SONG R H, LUO Z X, NIE J Y, et al. Identification of ambiguous queries in web search[J]. Information Processing & Management, 2009, 45(2): 216-229.
- [3] SANTOS R L T, MacDONALD C, OUNIS I. Search result diversification [J]. ACM SIGMOD Record, 2010, 39(1): 41-47.
- [4] ABID A, HUSSAIN N, ABID K, et al. A survey on search results diversification techniques [J]. Neural Computing and Applications, 2016, 27(5): 1207-1229.
- [5] 窦志成, 秦绪博, 文继荣. 搜索结果多样化研究综述 [J]. 计算机学报, 2019, 42(12): 2591-2613.
DOU Zhicheng, QIN Xubo, WEN Jirong. A survey on search result diversification [J]. Chinese Journal of Computers, 2019, 42(12): 2591-2613.
- [6] WU H L, ZHANG Y S, MA C, et al. A survey of diversification techniques in search and recommendation [J]. arXiv:2212.14464, 2022.
- [7] CARBONELL J, GOLDSTEIN J. The use of MMR, diversity-based reranking for reordering documents and producing summaries [C]//Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, 1998:335-336.
- [8] RADLINSKI F, BENNETT P N, CARTERETTE B, et al. Redundancy, diversity and interdependent document relevance [J]. ACM SIGIR Forum, 2009, 43(2): 46-52.
- [9] DROSOU M, PITOURA E. Search result diversification [J]. ACM SIGMOD Record, 2010, 39(1): 41-47.
- [10] XIA L, XU J, LAN Y Y, et al. Adapting Markov decision process for search result diversification [C]//Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2017:535-544.
- [11] FENG Y, XU J, LAN Y Y, et al. From greedy selection to exploratory decision-making: Diverse ranking with policy-value networks [C]//Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval, 2018:125-134.
- [12] ZHU Y D, LAN Y Y, GUO J F, et al. Learning for search result diversification [C]//Proceedings of the 37th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2014:293-302.
- [13] XIA L, XU J, LAN Y Y, et al. Learning maximal marginal relevance model via directly optimizing diversity evaluation measures [C]//Proceedings of the

- 38th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2015:113-122.
- [14] XIA L, XU J, LAN Y Y, et al. Modeling document novelty with neural tensor network for search result diversification[C]//Proceedings of the 39th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2016:395-404.
- [15] QIN X B, DOU Z C, ZHU Y T, et al. Interaction-based document matching for implicit search result diversification [C]//Proceedings of the 27th China Conference on Information Retrieval, 2021:3-15.
- [16] 秦绪博, 窦志成, 朱余韬, 等. 基于双星型自注意力网络的搜索结果多样化方法[C]//第二十届中国计算语言学大会, 2021:280-292.
- QIN Xubo, DOU Zhicheng, ZHU Yutao, et al. Search result diversification framework based on dual star-shaped self-attention network[C]//Proceedings of the 20th Chinese National Conference on Computational Linguistics, 2021:280-292.
- [17] YAN L, QIN Z, PASUMARTHI R K, et al. Diversification-aware learning to rank using distributed representation [C] // Proceedings of the 2021 Web Conference, 2021:127-136.
- [18] YU H-T. Optimize what you evaluate with; Search result diversification based on metric optimization [C]//Proceedings of the 36th AAAI Conference on Artificial Intelligence, 2022:10399-10407.
- [19] SU Z, DOU Z C, ZHU Y T, et al. Modeling intent graph for search result diversification[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2021:736-746.
- [20] XU X H, OUYANG K, ZHENG Y, et al. Diversify search results through graph attentive document interaction [C]//Proceedings of the 27th International Conference on Database Systems for Advanced Applications, 2022:632-647.
- [21] SU Z, DOU Z C, ZHU Y T, et al. Knowledge enhanced search result diversification [C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2022:1687-1695.
- [22] SU Z, DOU Z C, ZHU Y T, et al. Passage-aware search result diversification[J]. ACM Transactions on Information Systems, 2024, 42(5): Article No. : 139.
- [23] DENG Z R, DOU Z C, ZHU Y T, et al. CL4DIV: A contrastive learning framework for search result diversification [C]//Proceedings of the 17th ACM International Conference on Web Search and Data Mining, 2024:171-180.
- [24] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Proceedings of the 31st Conference on Neural Information Processing Systems, 2017:6000-6010.
- [25] DEVLIN J, CHANG M-W, LEE K, et al. BERT: Pre-training of deep bidirectional Transformers for language understanding [C] // Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019:4171-4186.
- [26] PANG L, XU J, AI Q Y, et al. SetRank: Learning a permutation-invariant ranking model for information retrieval [C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, 2020:499-508.
- [27] QIN X B, DOU Z C, WEN J R. Diversifying search results using self-attention network [C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management, 2020:1265-1274.
- [28] GUO Q P, QIU X P, LIU P F, et al. Star-Transformer [J]. arXiv:1902.09113, 2019.
- [29] CLARKE C L, KOLLA M, CORMACK G V, et al. Novelty and diversity in information retrieval evaluation[C]//Proceedings of the 31st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, 2008:659-666.
- [30] CHAPELLE O, METLZER D, ZHANG Y, et al. Expected reciprocal rank for graded relevance[C]//Proceedings of the 18th ACM Conference on Information and Knowledge Management, 2009:621-630.
- [31] BOLLACKER K, EVANS C, PARITOSH P, et al. Freebase: A collaboratively created graph database for structuring human knowledge [C]//Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data, 2008:1247-1250.
- [32] RADLINSKI F, SZUMMER M, CRASWELL N. Inferring query intent from reformulations and clicks [C]//Proceedings of the 19th International Conference on World Wide Web, 2010:1171-1172.
- [33] DANG V, XUE X B, CROFT W B. Inferring query aspects from reformulations using clustering[C]//Proceedings of the 20th ACM International Conference on Information and Knowledge Management, 2011:2117-2120.
- [34] MacAVANEY S, MacDONALD C, MURRAY-


- SMITH R, et al. IntenT5: Search result diversification using causal language models[J]. arXiv:2108.04026,2021.
- [35] LIU J N, DOU Z C, WANG X J, et al. DVGAN: A minimax game for search result diversification combining explicit and implicit features[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, 2020:479-488.
- [36] QIN X B, DOU Z C, ZHU Y T, et al. GDESA: Greedy diversity encoder with self-attention for search results diversification[J]. ACM Transactions on Information Systems, 2023, 41(2): Article No. : 34.
- [37] YU P X, RAHIMI R, HUANG Z Q, et al. Search result diversification using query aspects as bottlenecks [C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management, 2023:3040-3051.
- [38] OUYANG K, XU X H, XIE Z T, et al. Modeling global-local subtopic distribution with hypergraph to diversify search results[C]//Proceedings of the 2023 International Joint Conference on Neural Networks, 2023:1-8.
- [39] DENG Z R, DOU Z C, SU Z, et al. Multi-grained document modeling for search result diversification [J]. ACM Transactions on Information Systems, 2024, 42(5): Article No. :126.
- [40] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[J]. Communications of the ACM, 2020, 63(11):139-144.
- [41] WANG J, YU L T, ZHANG W W, et al. IRGAN: A minimax game for unifying generative and discriminative information retrieval models[C]//Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2017:515-524.
- [42] JIANG Z B, WEN J-R, DOU Z C, et al. Learning to diversify search results via subtopic attention [C]//Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2017:545-554.
- [43] TISHBY N, PEREIRA F C, BIALEK W. The information bottleneck method [J]. arXiv: physics/0004057, 2000.
- [44] ZHAI C X, COHEN W W, LAFFERTY J. Beyond independent relevance: Methods and evaluation metrics for subtopic retrieval[C]//Proceedings of the ACM SIGIR Fourm, 2015, 49(1):2-9.
- [45] MANNING C D, RAGHAVAN P, SCHÜTZE H. Introduction to information retrieval [M]. Cambridge:Cambridge University Press, 2008.
- [46] AGRAWAL R, GOLLAPUDI S, HALVERSON A, et al. Diversifying search results[C]//Proceedings of the 2nd ACM International Conference on Web Search and Data Mining, 2009:5-14.
- [47] CLARKE C L A, KOLLA M, VECHTOMOVA O. An effectiveness measure for ambiguous and under-specified queries[C]//Proceedings of the 2nd International Conference on the Theory of Information Retrieval: Advances in Information Retrieval Theory, 2009:188-199.
- [48] MOFFAT A, ZOBEL J. Rank-biased precision for measurement of retrieval effectiveness [J]. ACM Transactions on Information Systems, 2008, 27(1): Article No. :2.
- [49] YANG Y M, LAD A, LAO N, et al. Utility-based information distillation over temporally sequenced documents [C]//Proceedings of the 30th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, 2007:31-38.
- [50] SAKAI T, SONG R H. Evaluating diversified search results using per-intent graded relevance[C]//Proceedings of the 34th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2011:1043-1052.
- [51] AMIGÓ E, SPINA D, CARRILLO-de-ALBORNOZ J. An axiomatic analysis of diversity evaluation metrics: Introducing the rank-biased utility metric[C]//Proceedings of the 41st international ACM SIGIR Conference on Research and Development in Information Retrieval, 2018:625-634.
- [52] SAKAI T, ZENG Z Z. Which diversity evaluation measures are “good”? [C]//Proceedings of the 42nd international ACM SIGIR Conference on Research and Development in Information Retrieval, 2019: 595-604.
- [53] CLARKE C L A, CRASWELL N, SOBOROFF I. Overview of the TREC 2009 web track: ClarkeCS09 [R]. Gaithersburg: NIST Special Publication, 2009.
- [54] CLARKE C L, CRASWELL N, SOBOROFF I. Overview of the TREC 2010 web track: ClarkeCSC10 [R]. Gaithersburg: NIST Special Publication, 2010.
- [55] CLARKE C L, CRASWELL N, SOBOROFF I. Overview of the TREC 2011 web track: ClarkeCSV11 [R]. Gaithersburg: NIST Special Publication, 2011.
- [56] CLARKE C L, CRASWELL N, SOBOROFF I. Overview of the TREC 2012 web track: ClarkeCV12

- [R]. Gaithersburg: NIST Special Publication, 2012.
- [57] SONG R H, ZHANG M, SAKAI T, et al. Overview of the NTCIR-9 INTENT Task[C]//Proceedings of the 9th NTCIR Workshop Meeting on Evaluation of Information Access Technologies: Information Retrieval, Question Answering and Cross-Lingual Information Access, 2011: 82-105.
- [58] ABDOOL M, HALDAR M, RAMANATHAN P, et al. Managing diversity in Airbnb search[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2020: 2952-2960.
- [59] HALDAR M, ABDOOL M, HE L W, et al. Learning to rank diversely at Airbnb[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management, 2023: 4609-4615.
- [60] HUANG Y H, WANG W K, ZHANG L, et al. Sliding spectrum decomposition for diversified recommendation[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining, 2021: 3041-3049.
- [61] XU Y, CHEN H, WANG Z F, et al. Multi-factor sequential re-ranking with perception-aware diversification[C]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery & Data Mining, 2023: 5327-5337.
- [62] YIGIT-SERT S, ALTINGOVDE I S, MacDONALD C, et al. Explicit diversification of search results across multiple dimensions for educational search[J]. Journal of the Association for Information Science and Technology, 2021, 72(3): 315-330.
- [63] SANTOS R L T. Explicit web search result diversification[D]. Glasgow: University of Glasgow, 2013.
- [64] AKTOLGA E. Integrating non-topical aspects into information retrieval[D]. Amherst: University of Massachusetts, 2014.
- [65] McDONALD G, MacDONALD C, OUNIS I. Search results diversification for effective fair ranking in academic search[J]. Information Retrieval Journal, 2022, 25(1): 1-26.
- [66] WANG S T, DOU Z C, LIU J N, et al. Personalized and diversified: Ranking search results in an integrated way[J]. ACM Transactions on Information Systems, 2024, 42(3): Article No. :81.
- [67] LIU J N, DOU Z C, NIE J-Y, et al. Integrated personalized and diversified search based on search logs[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(2): 694-707.
- [68] WANG S T, DOU Z C, YAO J, et al. Incorporating explicit subtopics in personalized search[C]//Proceedings of the ACM Web Conference 2023, 2023: 3364-3374.
- [69] WANG W J, XU Y Y, FENG F L, et al. Diffusion recommender model[C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2023: 832-841.
- [70] YANG Z Y, WU J C, WANG Z C, et al. Generate what you prefer: Reshaping sequential recommendation via guided diffusion[C]//Proceedings of the 37th International Conference on Neural Information Processing Systems, 2023: Article No. :1054.
- [71] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Proceedings of the 34th Conference on Neural Information Processing Systems, 2020: 9459-9474.
- [72] WANG Z H, SHAO Y X, HE J Y, et al. Diversity-aware deep ranking network for recommendation[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management, 2023: 2564-2573.
- [73] YU H-T, JATOWT A, BLANCO R, et al. An in-depth study on diversity evaluation: The importance of intrinsic diversity[J]. Information Processing & Management, 2017, 53(4): 799-813.
- [74] ZHANG R Z, AI Q Y, WU Y Y, et al. Result diversification for legal case retrieval[C]//Proceedings of the 2023 Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region, 2023: 158-168.

作者简介:



李金忠 (1976—), 男, 江西吉安人, 博士, 副教授, CCF 高级会员 (15769S), 研究方向为信息检索、机器学习、大数据和人工智能。E-mail: lijnzhong@jgsu.edu.cn



LI Jinzhong, born in 1976, PhD, associate professor, CCF senior member (15769S), his research interests include information retrieval, machine learning, big data, and artificial intelligence.

刘伟东 (1998—), 男, 广东佛山人, 硕士生, 研究方向为人工智能、信息检索、排序学习。E-mail: wdliu@henu.edu.cn

LIU Weidong, born in 1998, MS candidate, his research interests include artificial intelligence, information retrieval and learning to rank.